

Statistisches Lernen zur Modellierung von Stratosphärischer Variabilität

Dipl.-Phys. Christian Blume
betreut von Prof. Dr. Katja Matthes

Institut für Meteorologie
Freie Universität Berlin

29. Juni 2012



Motivation

- Stratosphärische Variabilität ist das Ergebnis von komplexen Wechselwirkungen (z.B. Variabilität des Polarwirbels)

Motivation

- Stratosphärische Variabilität ist das Ergebnis von komplexen Wechselwirkungen (z.B. Variabilität des Polarwirbels)
- sie wird standardmäßig mit fortgeschrittenen Klima-Chemie-Modellen (CCMs) simuliert

Motivation

- Stratosphärische Variabilität ist das Ergebnis von komplexen Wechselwirkungen (z.B. Variabilität des Polarwirbels)
- sie wird standardmäßig mit fortgeschrittenen Klima-Chemie-Modellen (CCMs) simuliert
- CCMs sind jedoch rechenintensiv und machen es schwierig die Wichtigkeit von externen Faktoren direkt zu bestimmen

Motivation

- Stratosphärische Variabilität ist das Ergebnis von komplexen Wechselwirkungen (z.B. Variabilität des Polarwirbels)
- sie wird standardmäßig mit fortgeschrittenen Klima-Chemie-Modellen (CCMs) simuliert
- CCMs sind jedoch rechenintensiv und machen es schwierig die Wichtigkeit von externen Faktoren direkt zu bestimmen
- im Gegensatz: Statistische Modelle (STMs)
 - sind mathematisch einfacher
 - benötigen kaum Computerressourcen
 - Wichtigkeit externer Faktoren kann direkt bestimmt werden
 - können teilweise nichtlinear und nichtstationär modellieren

Motivation

- Stratosphärische Variabilität ist das Ergebnis von komplexen Wechselwirkungen (z.B. Variabilität des Polarwirbels)
- sie wird standardmäßig mit fortgeschrittenen Klima-Chemie-Modellen (CCMs) simuliert
- CCMs sind jedoch rechenintensiv und machen es schwierig die Wichtigkeit von externen Faktoren direkt zu bestimmen
- im Gegensatz: Statistische Modelle (STMs)
 - sind mathematisch einfacher
 - benötigen kaum Computerressourcen
 - Wichtigkeit externer Faktoren kann direkt bestimmt werden
 - können teilweise nichtlinear und nichtstationär modellieren
- Nachdem sie trainiert wurden, können STMs mit unbekanntem Input evaluiert werden → Vorhersage

Motivation

Was sind die Vorteile von fortschrittlichen STMs höherer Komplexität im Vergleich zu einfachen linearen Methoden?

Motivation

Was sind die Vorteile von fortschrittlichen STMs höherer Komplexität im Vergleich zu einfachen linearen Methoden?

Können STMs benutzt werden, um stratosphärisches Verhalten vorherzusagen?

Motivation

Was sind die Vorteile von fortschrittlichen STMs höherer Komplexität im Vergleich zu einfachen linearen Methoden?

Können STMs benutzt werden, um stratosphärisches Verhalten vorherzusagen?

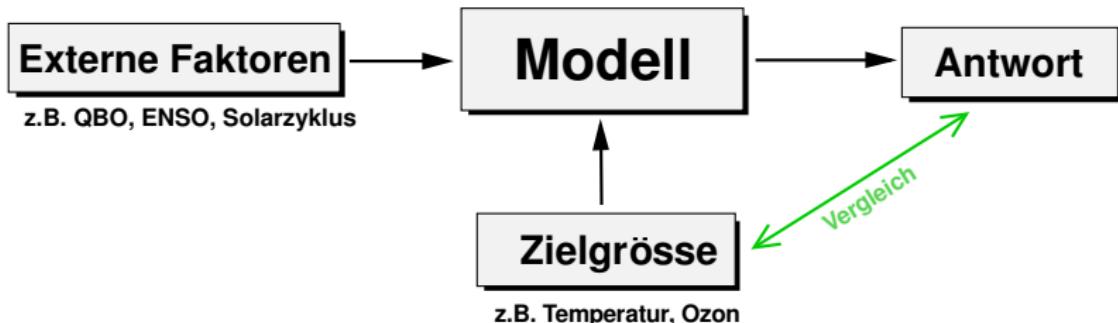
Welche der STMs sind am besten geeignet um stratosphärische Probleme zu lösen?

Motivation

Was sind die Vorteile von fortschrittlichen STMs höherer Komplexität im Vergleich zu einfachen linearen Methoden?

Können STMs benutzt werden, um stratosphärisches Verhalten vorherzusagen?

Welche der STMs sind am besten geeignet um stratosphärische Probleme zu lösen?



Gliederung

Gliederung

1 Statistische Methoden und Modellauswahl

Gliederung

- 1 Statistische Methoden und Modellauswahl**
- 2 Externe Faktoren und Daten**

Gliederung

- 1 Statistische Methoden und Modellauswahl**
- 2 Externe Faktoren und Daten**
- 3 Bestimmung von natürlicher Variabilität**

Gliederung

- 1 Statistische Methoden und Modellauswahl
- 2 Externe Faktoren und Daten
- 3 Bestimmung von natürlicher Variabilität
- 4 Klassifizierung von Stratosphärenerwärmungen

Gliederung

- 1 Statistische Methoden und Modellauswahl
- 2 Externe Faktoren und Daten
- 3 Bestimmung von natürlicher Variabilität
- 4 Klassifizierung von Stratosphärenerwärmungen
- 5 Vorhersage von Polarer Variabilität

Gliederung

- 1 Statistische Methoden und Modellauswahl
- 2 Externe Faktoren und Daten
- 3 Bestimmung von natürlicher Variabilität
- 4 Klassifizierung von Stratosphärenerwärmungen
- 5 Vorhersage von Polarer Variabilität
- 6 Zusammenfassung

Gliederung

- 1 Statistische Methoden und Modellauswahl
- 2 Externe Faktoren und Daten
- 3 Bestimmung von natürlicher Variabilität
- 4 Klassifizierung von Stratosphärenerwärmungen
- 5 Vorhersage von Polarer Variabilität
- 6 Zusammenfassung
- 7 Fazit

Statistische Methoden

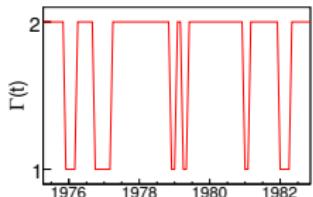
$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta}$$

LDA [Montgomery et al., 2006; Wilks, 1995] Lineare Diskriminanzanalyse (**linear, stationär**) 

Statistische Methoden

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta}$$

LDA [Montgomery et al., 2006; Wilks, 1995] Lineare Diskriminanzanalyse (**linear, stationär**) 

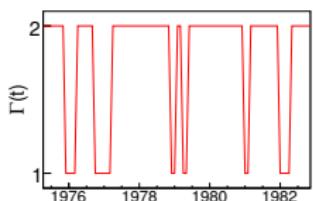


FEM-VARX [Horenko, 2010, 2011] Clustermethode plus Vektorautoregression mit externen Faktoren (**lokal linear in Clustern, nichtstationär**) 

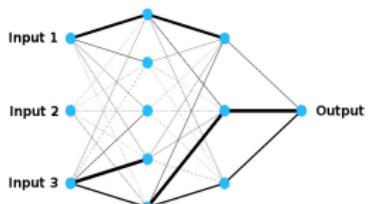
Statistische Methoden

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta}$$

LDA [Montgomery et al., 2006; Wilks, 1995] Lineare Diskriminanzanalyse (**linear, stationär**) 



FEM-VARX [Horenko, 2010, 2011] Clustermethode plus Vektorautoregression mit externen Faktoren (**lokal linear in Clustern, nichtstationär**) 

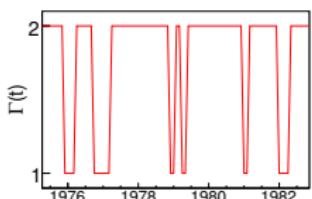


MLP [Bishop, 1995; Zhang et al., 1998]
Multi-Layer Perceptron; Ein vorwärts-gekoppeltes, voll verbundenes Neuronales Netz
(**nichtlinear, stationär**) 

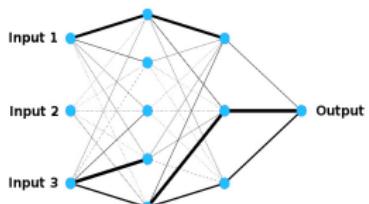
Statistische Methoden

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta}$$

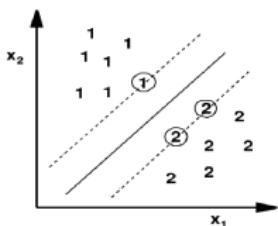
LDA [Montgomery et al., 2006; Wilks, 1995] Lineare Diskriminanzanalyse (**linear, stationär**) 



FEM-VARX [Horenko, 2010, 2011] Clustermethode plus Vektorautoregression mit externen Faktoren (**lokal linear in Clustern, nichtstationär**) 



MLP [Bishop, 1995; Zhang et al., 1998] Multi-Layer Perceptron; Ein vorwärts-gekoppeltes, voll verbundenes Neuronales Netz (**nichtlinear, stationär**) 



SVM [Burges, 1998; Vapnik, 1995] Support Vector Machine (**nichtlinear, stationär**) 

Modellauswahl

I.d.R. besitzen STMs einen Satz von Parametern, der vor dem eigentlichen Training bestimmt werden muss.

Modellauswahl

I.d.R. besitzen STMs einen Satz von Parametern, der vor dem eigentlichen Training bestimmt werden muss.

Beispiele von Parametern sind die Anzahl von Neuronen in den versteckten Schichten des MLP oder die Anzahl von Clustern in FEM-VARX.

▶ Bsp. ▶ Bsp.

Modellauswahl

I.d.R. besitzen STMs einen Satz von Parametern, der vor dem eigentlichen Training bestimmt werden muss.

Beispiele von Parametern sind die Anzahl von Neuronen in den versteckten Schichten des MLP oder die Anzahl von Clustern in FEM-VARX. ▶ Bsp. ▶ Bsp.

Jeder Satz von möglichen Parametern kann als ein Modell angesehen werden → Modellauswahl.

Modellauswahl

I.d.R. besitzen STMs einen Satz von Parametern, der vor dem eigentlichen Training bestimmt werden muss.

Beispiele von Parametern sind die Anzahl von Neuronen in den versteckten Schichten des MLP oder die Anzahl von Clustern in FEM-VARX.

▶ Bsp. ▶ Bsp.

Jeder Satz von möglichen Parametern kann als ein Modell angesehen werden → Modellauswahl.

Das optimale Modell ist jenes, welches genauso viel Informationen enthält, wie jedes kompliziertere Modell.

→ Ockhams Rasiermesser [Ariew, 1976]

Methoden der Modellauswahl

Zwei Hauptzweige der Modellauswahl:

Methoden der Modellauswahl

Zwei Hauptzweige der Modellauswahl:

1) Informationskriterien [z.B. Liddle, 2008]

- Minimierung von: Trainingsfehler + Anzahl von Parametern
- Akaike Informationskriterium (AIC) [Akaike, 1974]
- Bayessche Informationskriterium (BIC) [Schwarz, 1978]
- Anwendbar auf: FEM-VARX, MLP, LDA

Methoden der Modellauswahl

Zwei Hauptzweige der Modellauswahl:

1) Informationskriterien [z.B. Liddle, 2008]

- Minimierung von: Trainingsfehler + Anzahl von Parametern
- Akaike Informationskriterium (AIC) [Akaike, 1974]
- Bayessche Informationskriterium (BIC) [Schwarz, 1978]
- Anwendbar auf: FEM-VARX, MLP, LDA

2) Kreuzvalidierung [z.B. Kohavi, 1995]

- Minimierung von: Vorhersagefehler
- k -fold Kreuzvalidierung mit k zusammenhängenden Intervallen
- Anwendbar auf: SVM, MLP, LDA

Methoden der Modellauswahl

Zwei Hauptzweige der Modellauswahl:

1) Informationskriterien [z.B. Liddle, 2008]

- Minimierung von: Trainingsfehler + Anzahl von Parametern
- Akaike Informationskriterium (AIC) [Akaike, 1974]
- Bayessche Informationskriterium (BIC) [Schwarz, 1978]
- Anwendbar auf: FEM-VARX, MLP, LDA

2) Kreuzvalidierung [z.B. Kohavi, 1995]

- Minimierung von: Vorhersagefehler
- k -fold Kreuzvalidierung mit k zusammenhängenden Intervallen
- Anwendbar auf: SVM, MLP, LDA

Beide Ansätze versuchen einen Ausgleich zwischen der Approximation der Trainingsdaten und der Generalisierung zu unbekannten Daten herzustellen ⇒ Mustererkennung

Externe Faktoren

Externe Faktoren

Die wichtigsten Forcings und Variabilitätsmoden, welche die stratosphärische Variabilität beeinflussen 

- Quasi-Biennial Oscillation (QBO) [Baldwin et al., 2001] 
- Arktische Oszillation (NAM) und
Antarktische Oszillation (SAM) [Baldwin and Dunkerton, 2001] 
- Variabilität in Meeresoberflächentemperatur (z.B. ENSO,
PDO, AMO) [Deser et al., 2010] 
- 11-jähriger Solarzyklus [Gray et al., 2010] 
- Vulkanische Eruptionen [Robock, 2000] 

Externe Faktoren

Die wichtigsten Forcings und Variabilitätsmoden, welche die stratosphärische Variabilität beeinflussen



- Quasi-Biennial Oscillation (QBO) [Baldwin et al., 2001]
- Arktische Oszillation (NAM) und
Antarktische Oszillation (SAM) [Baldwin and Dunkerton, 2001]
- Variabilität in Meeresoberflächentemperatur (z.B. ENSO,
PDO, AMO) [Deser et al., 2010]
- 11-jähriger Solarzyklus [Gray et al., 2010]
- Vulkanische Eruptionen [Robock, 2000]

Zusätzliche Basisfaktoren:

- Jahresgang (Langzeitliches Mittel bzw. Sinus-Kosinus)
- Trendgröße: linear für Geopotential, Temperatur
 $ESC = CI + 60 \cdot Br$ für Ozon Forcings

Daten

- Beobachtungen (Ozon)
 - NIWA-3D [Hassler et al., 2009]
 - Randel&Wu [Randel and Wu, 2007]

Daten

- Beobachtungen (Ozon)
 - NIWA-3D [Hassler et al., 2009]
 - Randel&Wu [Randel and Wu, 2007]
- Reanalysen
 - ERA-40 [Uppala et al., 2005]
 - ERA-Interim [Simmons et al., 2006]
 - NCEP/NCAR [Kalnay et al., 1996]
 - MERRA [Rienecker et al., 2011]

Daten

- Beobachtungen (Ozon)
 - NIWA-3D [Hassler et al., 2009]
 - Randel&Wu [Randel and Wu, 2007]
- Reanalysen
 - ERA-40 [Uppala et al., 2005]
 - ERA-Interim [Simmons et al., 2006]
 - NCEP/NCAR [Kalnay et al., 1996]
 - MERRA [Rienecker et al., 2011]
- Modellsimulationen [SPARC CCMVal, 2010]
 - EMAC-FUB: **ECHAM5/MESSy Atmospheric Chemistry model**
 - MRI: The **Meteorological Research Institute** model
 - WACCM: The **Whole Atmosphere Community Climate Model**
→ REF-B1 (1960-2005) and REF-B2 (1960-2100)

Daten

- Beobachtungen (Ozon)
 - NIWA-3D [Hassler et al., 2009]
 - Randel&Wu [Randel and Wu, 2007]
- Reanalysen
 - ERA-40 [Uppala et al., 2005]
 - ERA-Interim [Simmons et al., 2006]
 - NCEP/NCAR [Kalnay et al., 1996]
 - MERRA [Rienecker et al., 2011]
- Modellsimulationen [SPARC CCMVal, 2010]
 - EMAC-FUB: **ECHAM5/MESSy Atmospheric Chemistry model**
 - MRI: The **Meteorological Research Institute** model
 - WACCM: The **Whole Atmosphere Community Climate Model**

→ REF-B1 (1960-2005) and REF-B2 (1960-2100)

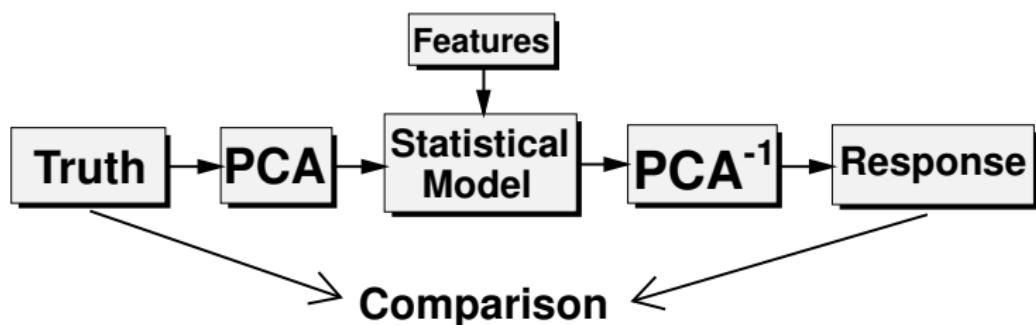
→ Alle Daten sind Anomalien bzgl. ihres Langzeitmittels

Bestimmung von natürlicher Variabilität

Ziel: Quantifizierung der Wichtigkeit von natürlichen Faktoren für die Variabilität der globalen Stratosphäre (100 - 1 hPa) anhand von Temperatur und Ozon für das rezente Klima (1980–2005).

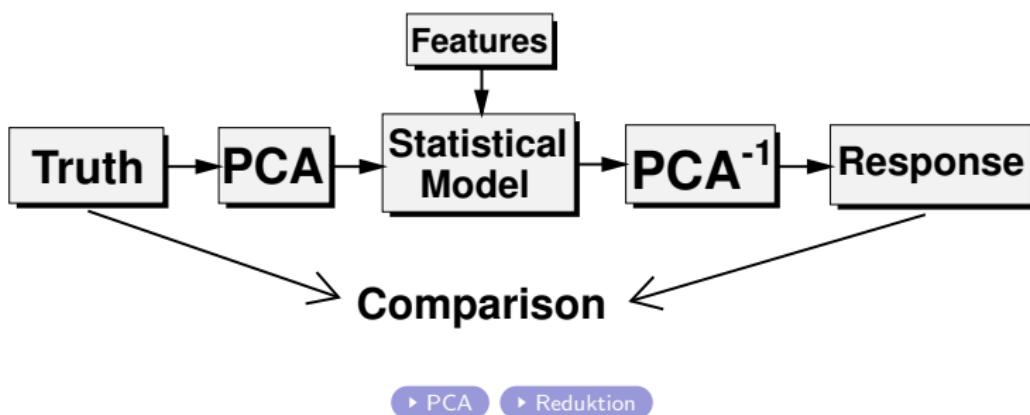
Bestimmung von natürlicher Variabilität

Ziel: Quantifizierung der Wichtigkeit von natürlichen Faktoren für die Variabilität der globalen Stratosphäre (100 - 1 hPa) anhand von Temperatur und Ozon für das rezente Klima (1980–2005).



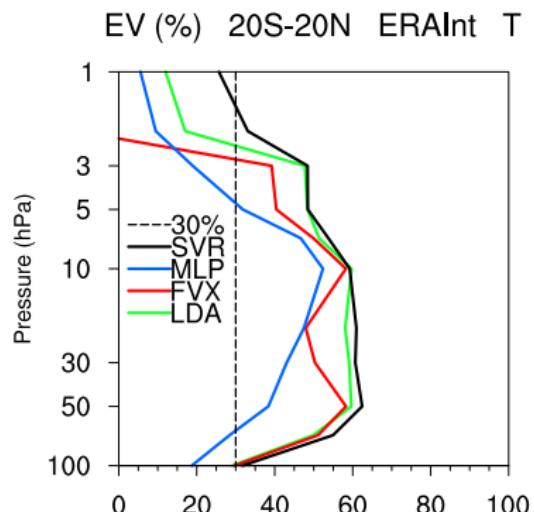
Bestimmung von natürlicher Variabilität

Ziel: Quantifizierung der Wichtigkeit von natürlichen Faktoren für die Variabilität der globalen Stratosphäre (100 - 1 hPa) anhand von Temperatur und Ozon für das rezente Klima (1980–2005).

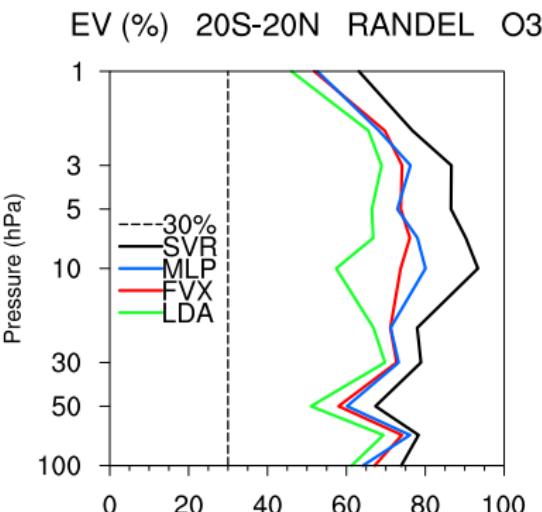
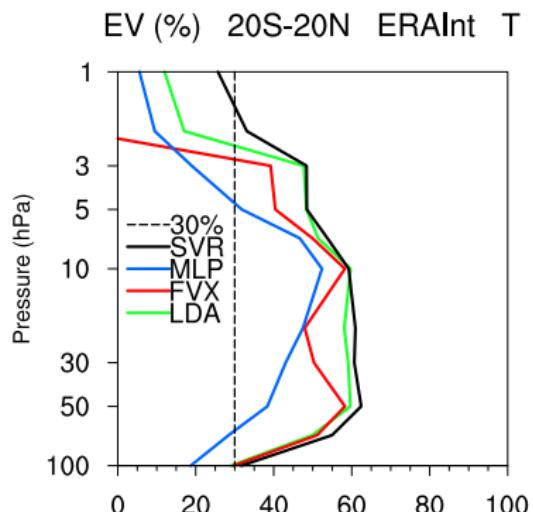


- Training mit der reduzierten Repräsentierung
- Vorhersage für das zukünftliche Klima (2006–2100)

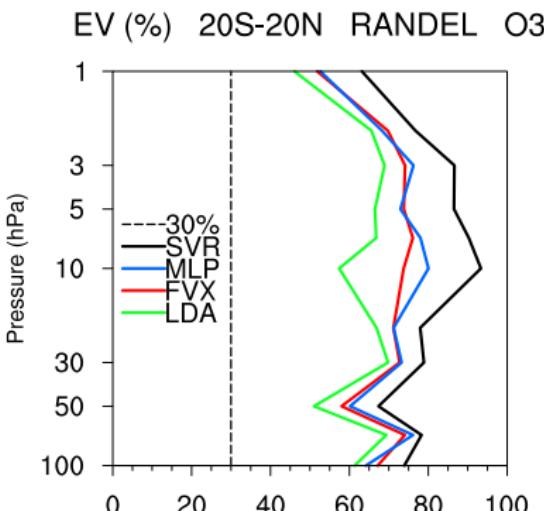
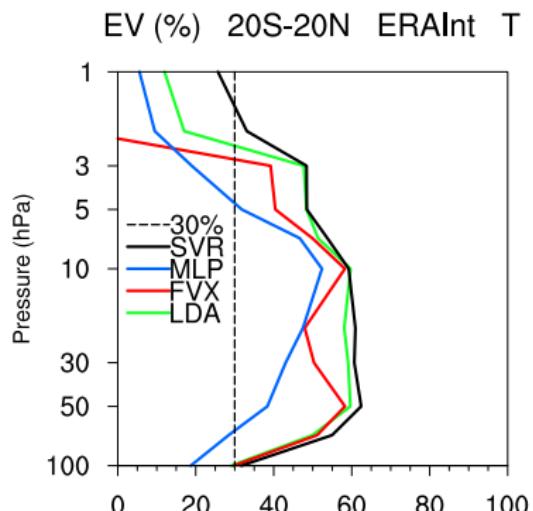
Güte der Regression



Güte der Regression



Güte der Regression



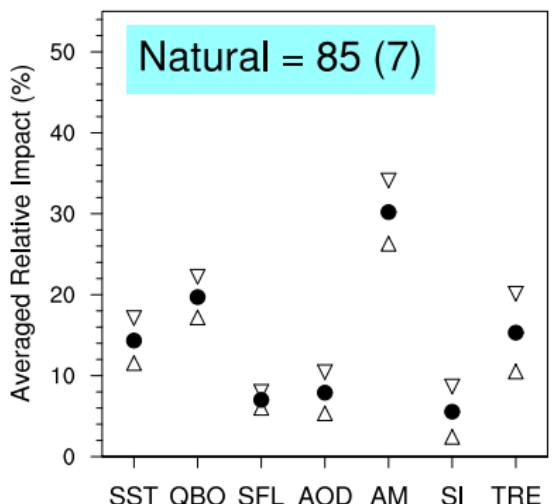
T					O ₃				
LDA	FVX	MLP	SVR		LDA	FVX	MLP	SVR	
26±3	26±2	26±2	39±1		54±3	60±3	58±4	76±3	

► Regressionsgüte Detailliert

Natürliche Variabilität im Mittel

$$\text{Impact}_k = \sigma(Y - Y^k)$$

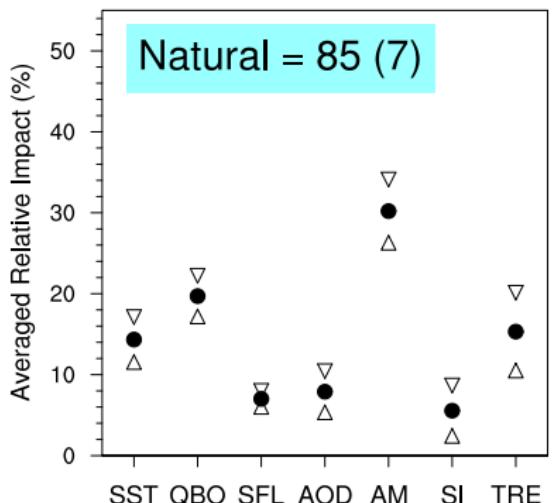
Impact(%) Temperature



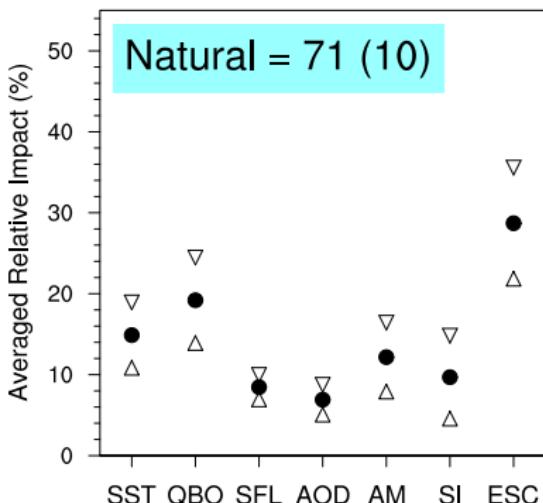
Natürliche Variabilität im Mittel

$$\text{Impact}_k = \sigma(Y - Y^k)$$

Impact(%) Temperature



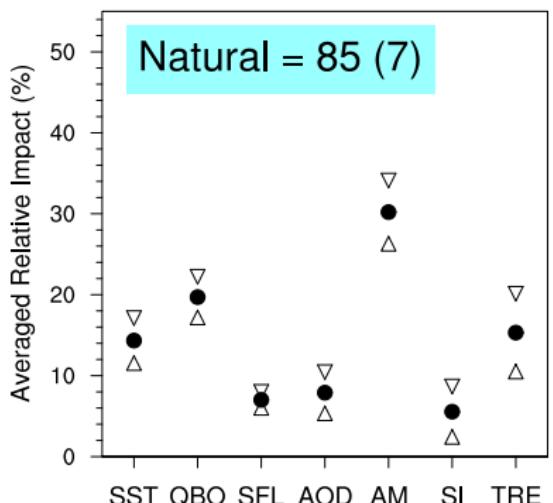
Impact(%) Ozone



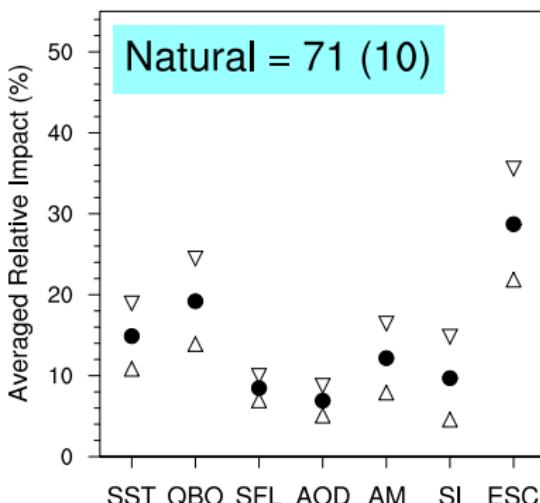
Natürliche Variabilität im Mittel

$$\text{Impact}_k = \sigma(Y - Y^k)$$

Impact(%) Temperature



Impact(%) Ozone



SPARC CCMVal [2010], Kapitel 8

⇒ Mind. 8% (Temperatur) bzw. 19% (Ozon) der Variabilität ist anthropogenen Ursprungs.

► Individuell

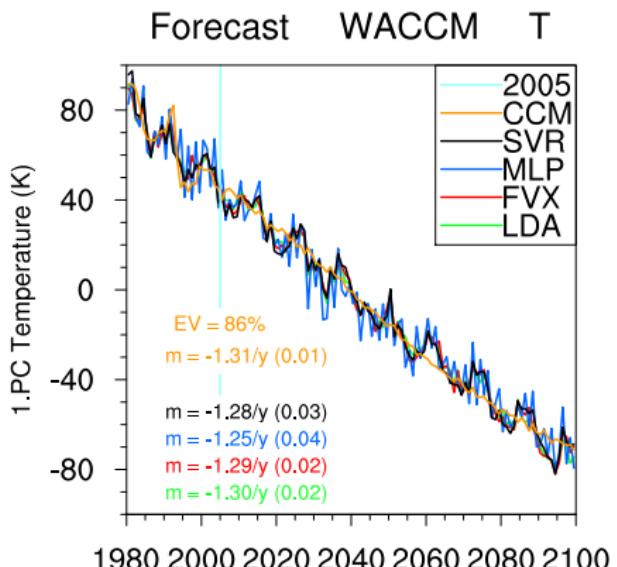
► Regional

Langfristige Vorhersage

... unter der Annahme von sinnvollen externen Faktoren.

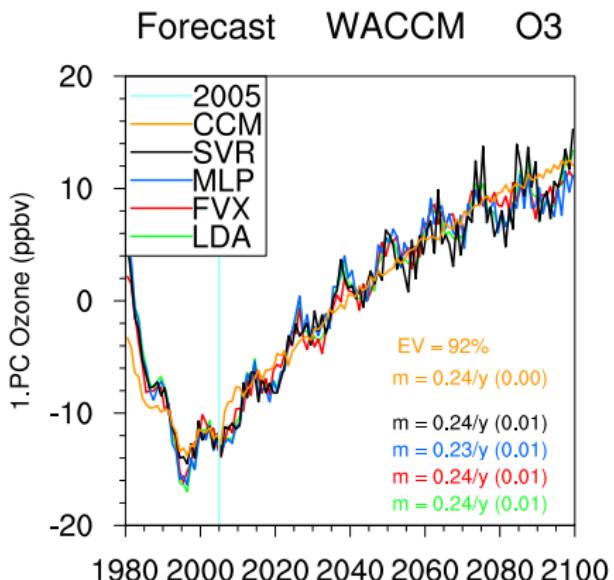
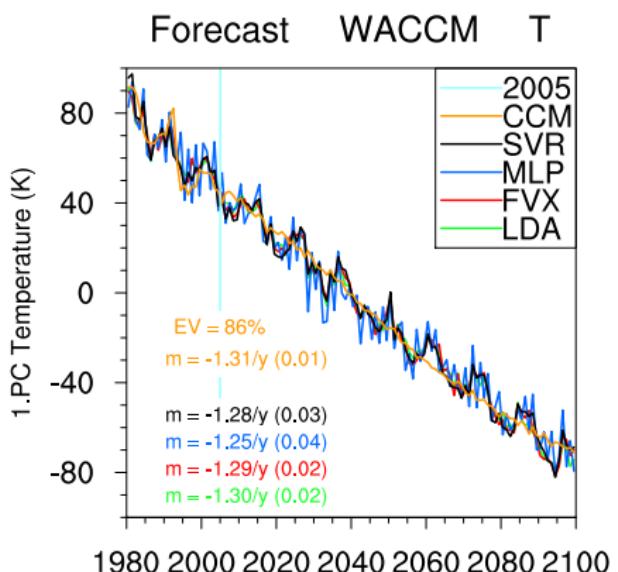
Langfristige Vorhersage

... unter der Annahme von sinnvollen externen Faktoren.



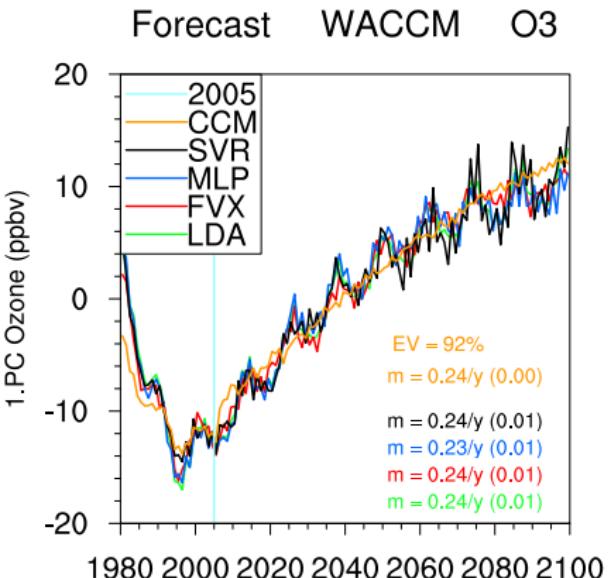
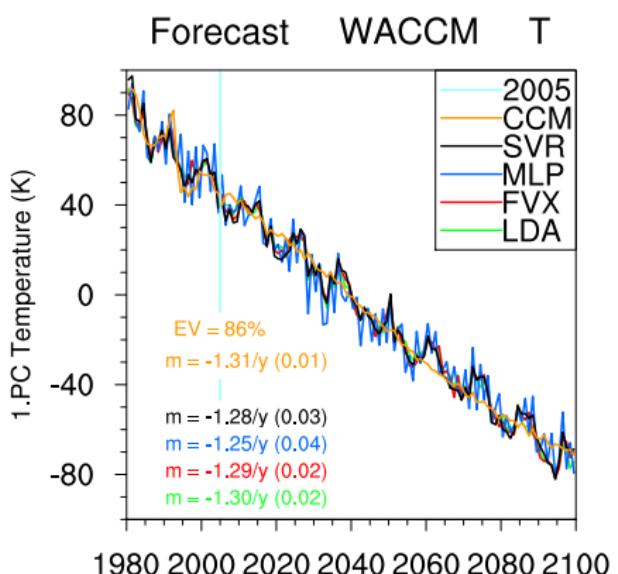
Langfristige Vorhersage

... unter der Annahme von sinnvollen externen Faktoren.



Langfristige Vorhersage

... unter der Annahme von sinnvollen externen Faktoren.



	LDA	FVX	MLP	SVR
--	-----	-----	-----	-----

T	0.96	0.96	0.96	0.96
O ₃	0.95	0.95	0.90	0.96

▶ Vergleich mit EOFs

Klassifizierung von Stratosphärenerwärmungen

Blume et al. 2012, JAS, 69(6), 1824-1840

Klassifizierung von Stratosphärenerwärmungen

Blume et al. 2012, JAS, 69(6), 1824–1840

- Klassifizierung von Major, Minor und Final Warmings ▶ SSWs im selben statistischen Framework (1958–2010)

Klassifizierung von Stratosphärenerwärmungen

Blume et al. 2012, JAS, 69(6), 1824–1840

- Klassifizierung von Major, Minor und Final Warmings ▶ SSWs im selben statistischen Framework (1958–2010)
- Als Indikator dient eine Temperaturanomalie in der polaren, mittleren Stratosphäre (PC1) sowie das Langzeitmittel der polaren Temperatur in 30 hPa

Klassifizierung von Stratosphärenwärmungen

Blume et al. 2012, JAS, 69(6), 1824–1840

- Klassifizierung von Major, Minor und Final Warmings ▶ SSWs im selben statistischen Framework (1958–2010)
- Als Indikator dient eine Temperaturanomalie in der polaren, mittleren Stratosphäre (PC1) sowie das Langzeitmittel der polaren Temperatur in 30 hPa
- Externe Faktoren sind ENSO, QBO und Solarzyklus ▶ Lags
→ Erweiterung des Wind-Maßes und des NAM-Maßes

Klassifizierung von Stratosphärenerwärmungen

Blume et al. 2012, JAS, 69(6), 1824–1840

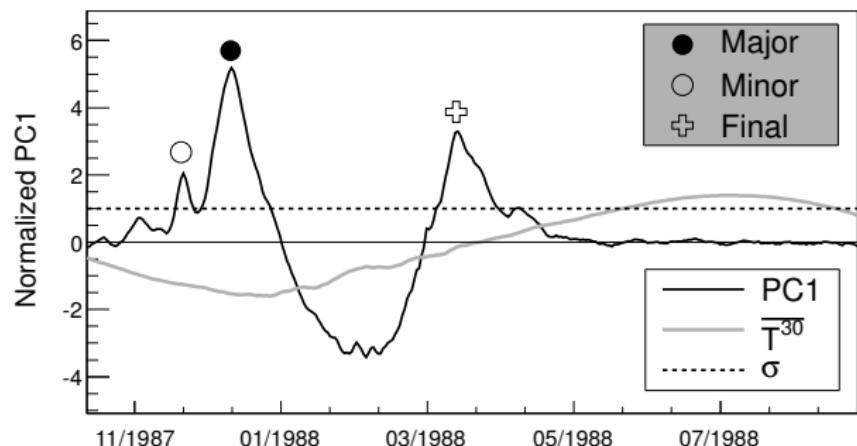
- Klassifizierung von Major, Minor und Final Warmings ▶ SSWs im selben statistischen Framework (1958–2010)
- Als Indikator dient eine Temperaturanomalie in der polaren, mittleren Stratosphäre (PC1) sowie das Langzeitmittel der polaren Temperatur in 30 hPa
- Externe Faktoren sind ENSO, QBO und Solarzyklus ▶ Lags → Erweiterung des Wind-Maßes und des NAM-Maßes
- Ein MLP kombiniert die fünf Faktoren und nutzt deren nichtlineare Korrelationen aus ▶ Korr. Matrix

Klassifizierung von Stratosphärenerwärmungen

Blume et al. 2012, JAS, 69(6), 1824–1840

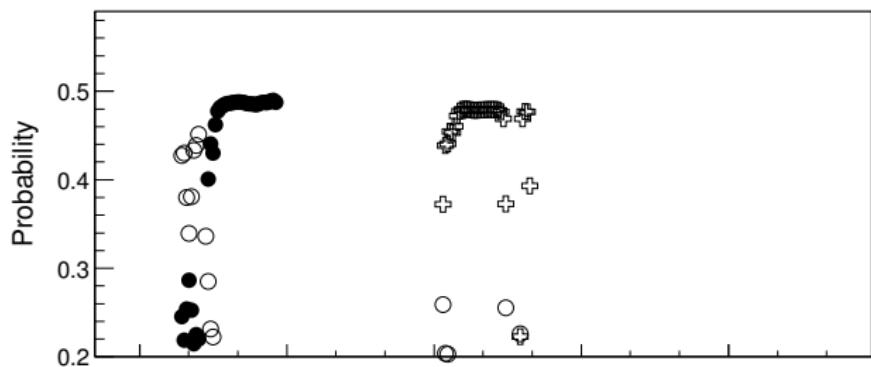
- Klassifizierung von Major, Minor und Final Warmings ▶ SSWs im selben statistischen Framework (1958–2010)
- Als Indikator dient eine Temperaturanomalie in der polaren, mittleren Stratosphäre (PC1) sowie das Langzeitmittel der polaren Temperatur in 30 hPa
- Externe Faktoren sind ENSO, QBO und Solarzyklus ▶ Lags → Erweiterung des Wind-Maßes und des NAM-Maßes
- Ein MLP kombiniert die fünf Faktoren und nutzt deren nichtlineare Korrelationen aus ▶ Korr. Matrix
- MLP diskriminiert bedeutend besser als LDA oder SVM mit linearem Kernel ▶ Performance

Trainingsdaten vs. MLP Wahrscheinlichkeiten



Winter 1987/88

Training:
ERA-40/ERA-Int



Validierung:
NCEP/NCAR

► Validierung Zonalwind

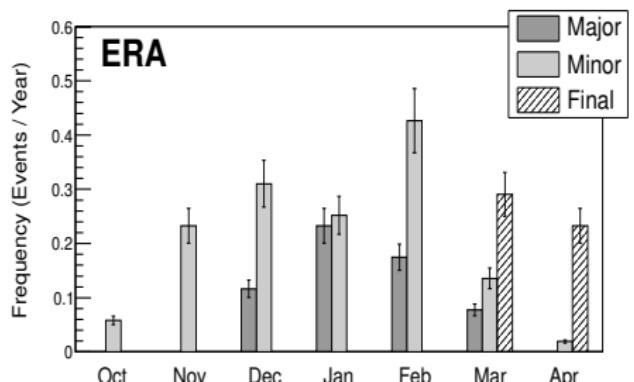
► Training Sample

Anzahlen und Monatliche Verteilungen

Data	Major	Minor	Final	Total
ERA	31	74	27	132
NCEP	26	76	28	130
ERA	0.6 (0.1)	1.4 (0.2)	0.5 (0.1)	2.5 (0.3)
NCEP	0.5 (0.1)	1.5 (0.2)	0.5 (0.1)	2.5 (0.3)

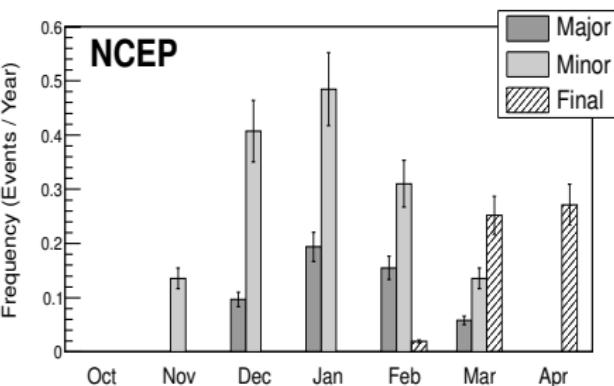
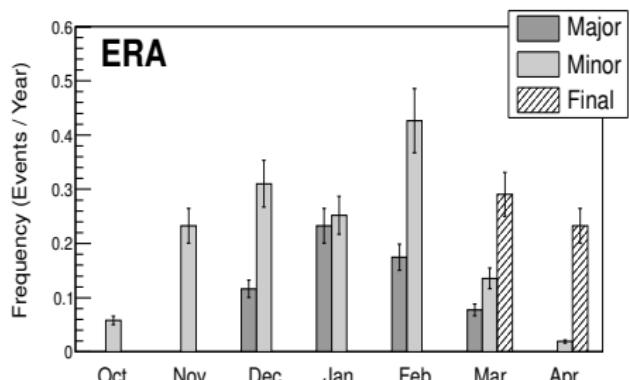
Anzahlen und Monatliche Verteilungen

Data	Major	Minor	Final	Total
ERA	31	74	27	132
NCEP	26	76	28	130
ERA	0.6 (0.1)	1.4 (0.2)	0.5 (0.1)	2.5 (0.3)
NCEP	0.5 (0.1)	1.5 (0.2)	0.5 (0.1)	2.5 (0.3)



Anzahlen und Monatliche Verteilungen

Data	Major	Minor	Final	Total
ERA	31	74	27	132
NCEP	26	76	28	130
ERA	0.6 (0.1)	1.4 (0.2)	0.5 (0.1)	2.5 (0.3)
NCEP	0.5 (0.1)	1.5 (0.2)	0.5 (0.1)	2.5 (0.3)



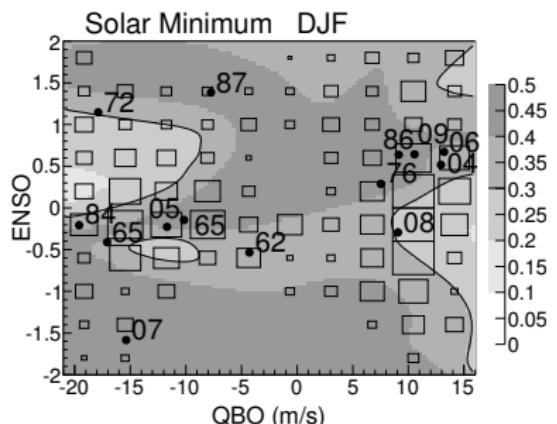
Einfluss der Faktoren

Faktor	Major	Minor	Final
$\overline{T^{30}}$	22.2	22.4	54.0
PC1	26.9	23.7	31.2
QBO	19.3	19.9	4.6
ENSO	17.4	17.9	4.9
SFL	14.3	15.9	5.3

Einfluss der Faktoren

Faktor	Major	Minor	Final
T^{30}	22.2	22.4	54.0
PC1	26.9	23.7	31.2
QBO	19.3	19.9	4.6
ENSO	17.4	17.9	4.9
SFL	14.3	15.9	5.3

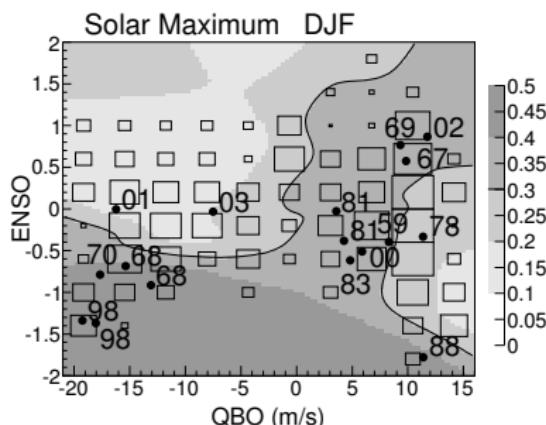
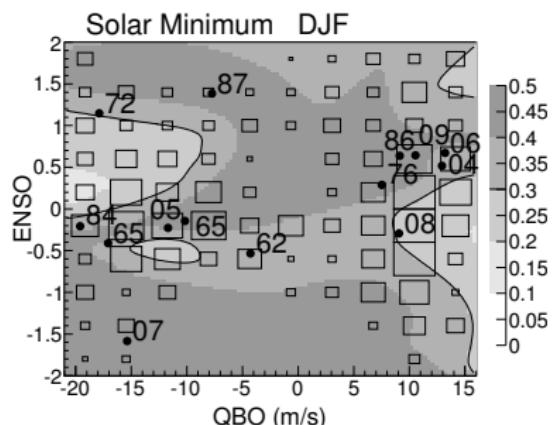
- ▶ Camp and Tung [2007]
- ▶ Labitzke et al. [2006]
- ▶ Mitchell et al. [2011]



Einfluss der Faktoren

Faktor	Major	Minor	Final
T^{30}	22.2	22.4	54.0
PC1	26.9	23.7	31.2
QBO	19.3	19.9	4.6
ENSO	17.4	17.9	4.9
SFL	14.3	15.9	5.3

- ▶ Camp and Tung [2007]
- ▶ Labitzke et al. [2006]
- ▶ Mitchell et al. [2011]

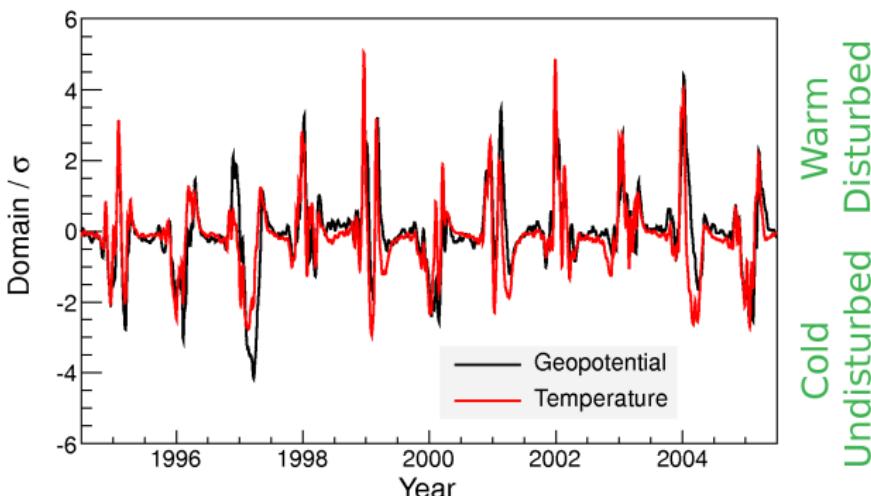


Vorhersage von Polarer Variabilität

Blume and Matthes 2012, ACP, in press

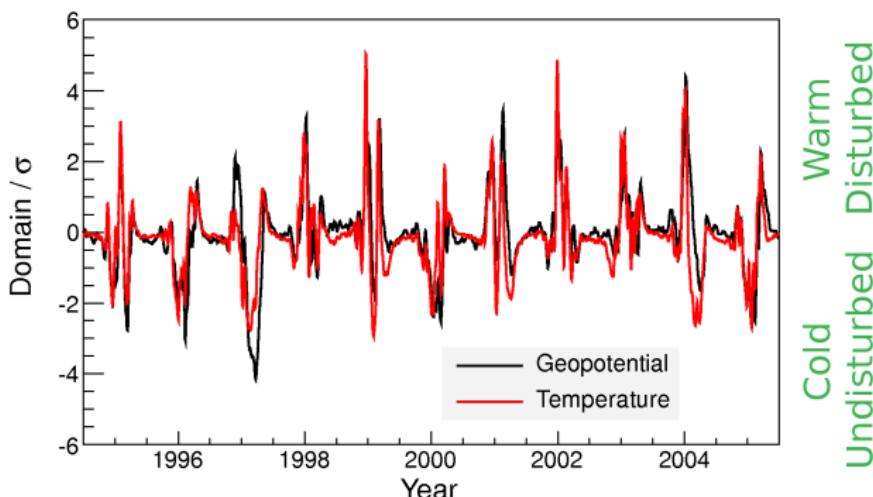
Vorhersage von Polarer Variabilität

Blume and Matthes 2012, ACP, in press



Vorhersage von Polarer Variabilität

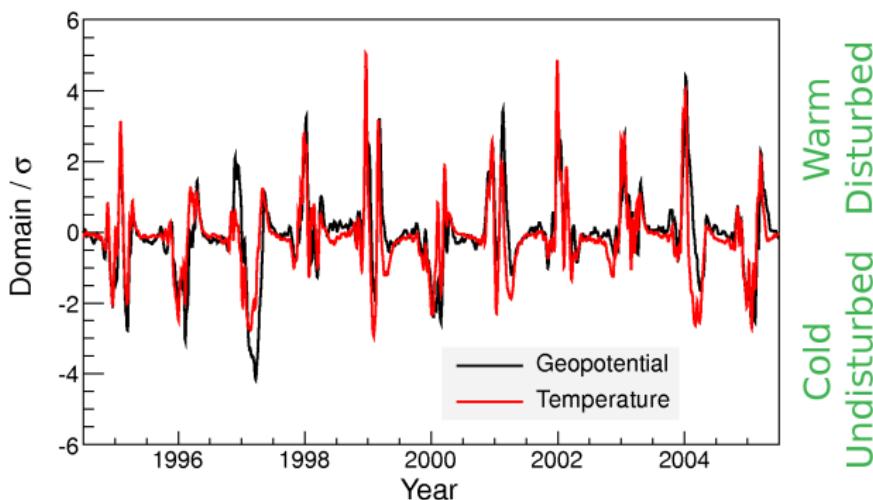
Blume and Matthes 2012, ACP, in press



→ reflektiert die Variabilität in der mittleren polaren Stratosphäre
▶ Korrelation und damit auch Stratosphärenwärmungen

Vorhersage von Polarer Variabilität

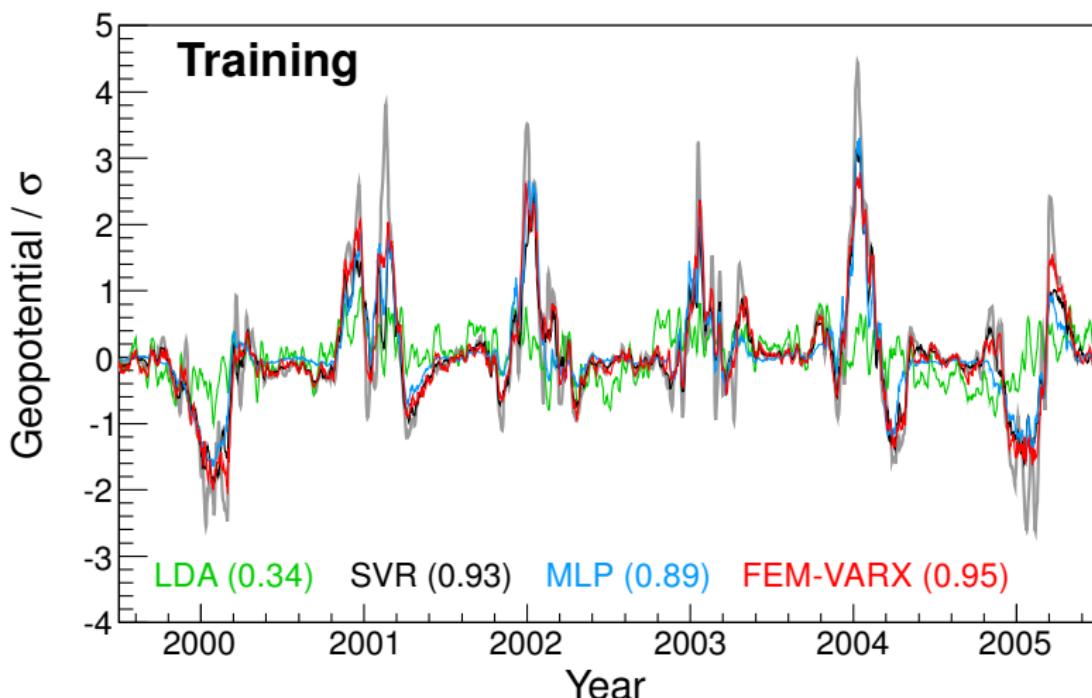
Blume and Matthes 2012, ACP, in press



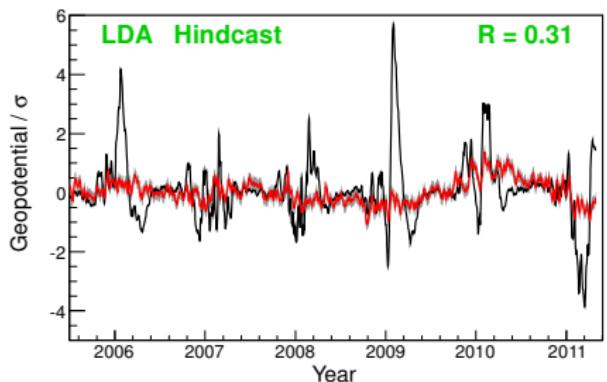
→ reflektiert die Variabilität in der mittleren polaren Stratosphäre
▶ Korrelation und damit auch Stratosphärenwärmungen

ERA-Interim ▶ Faktoren Training: 1980–2005 Hindcast: 2005–2011

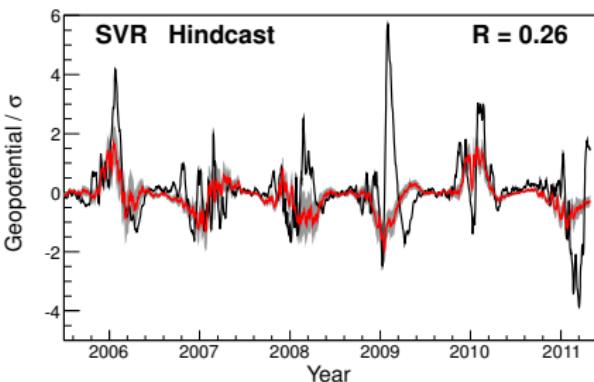
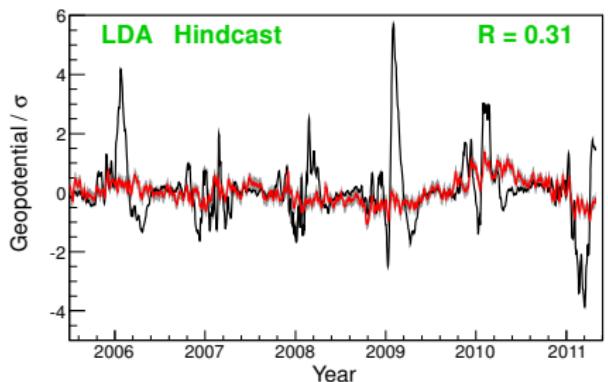
Resultate auf der Trainingsperiode



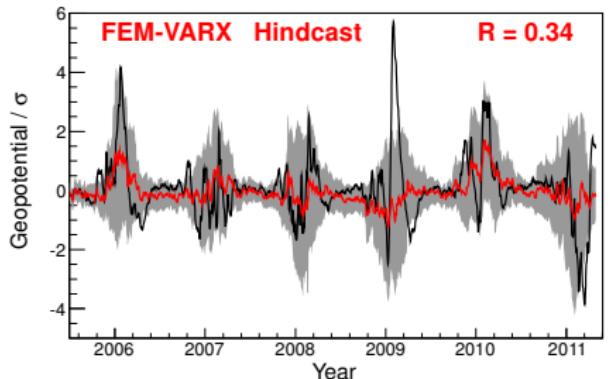
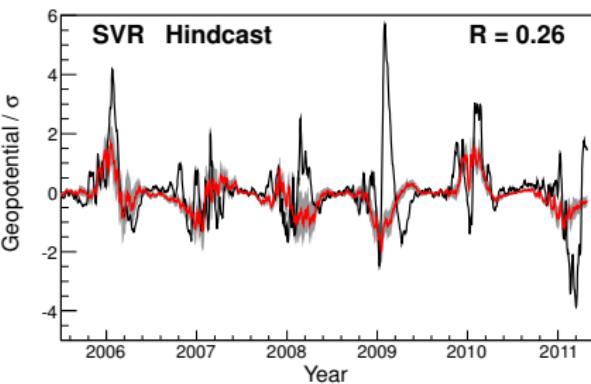
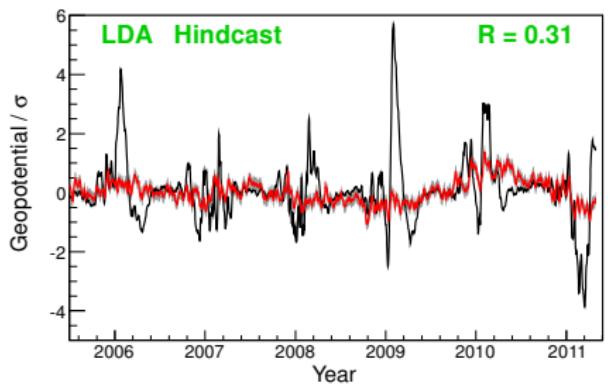
Resultate auf der Hindcastperiode



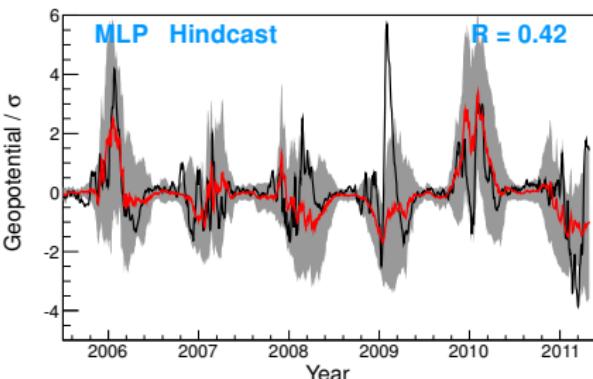
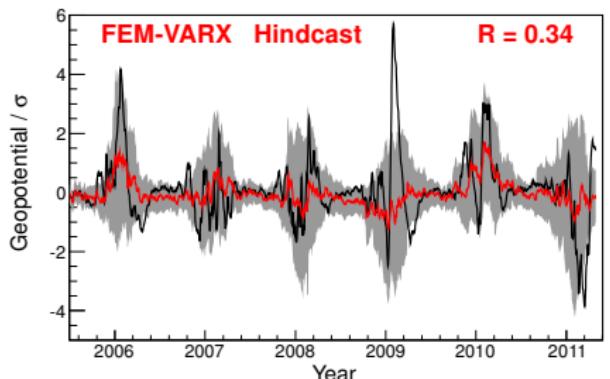
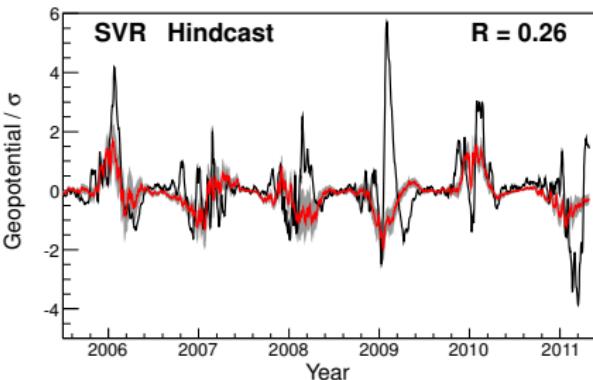
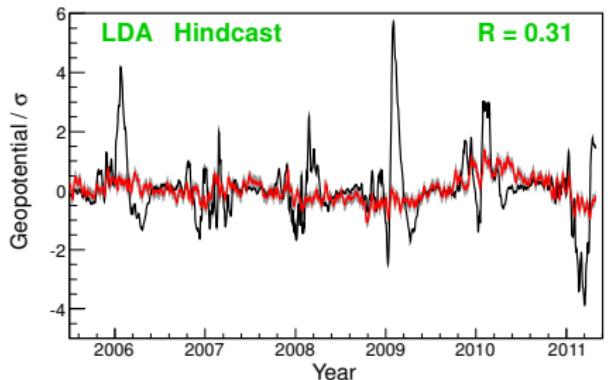
Resultate auf der Hindcastperiode



Resultate auf der Hindcastperiode



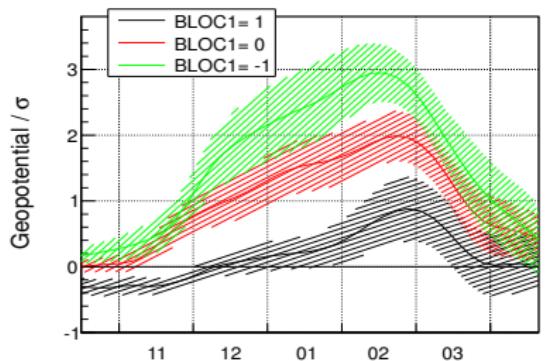
Resultate auf der Hindcastperiode



► Temperatur

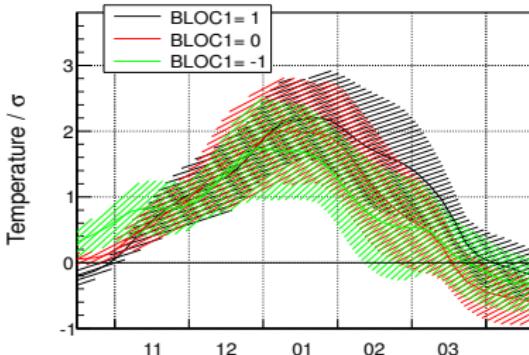
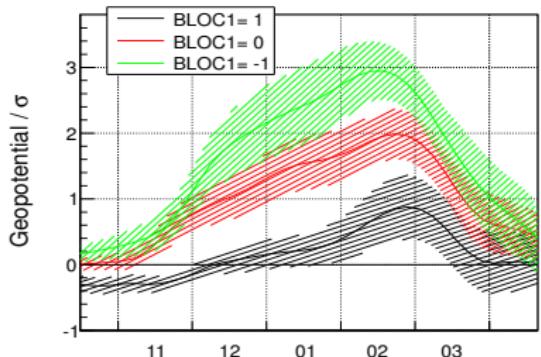
Vorhersage des Winters 2011/12

► Annahmen



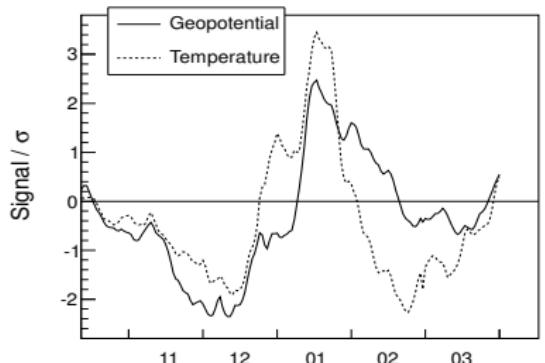
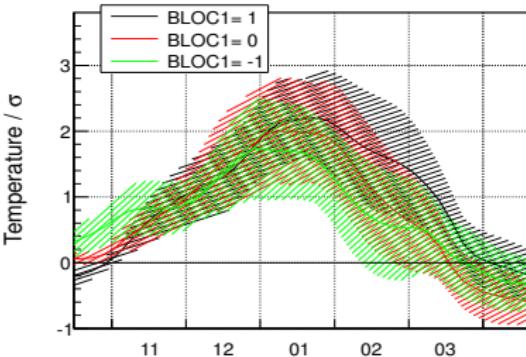
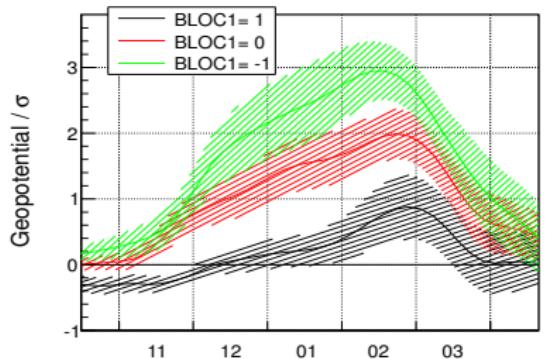
Vorhersage des Winters 2011/12

► Annahmen



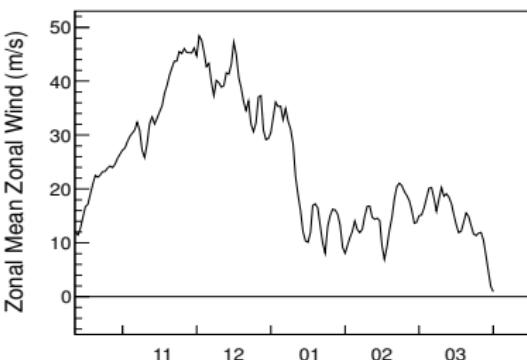
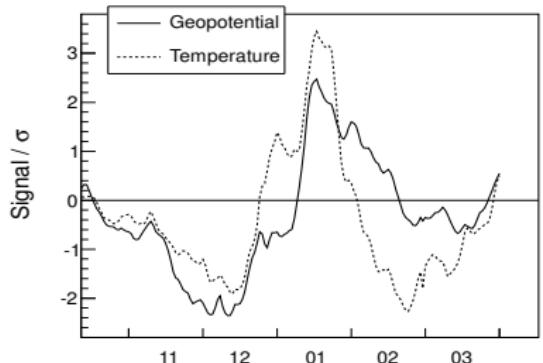
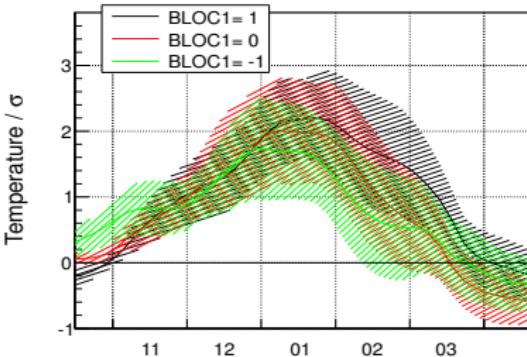
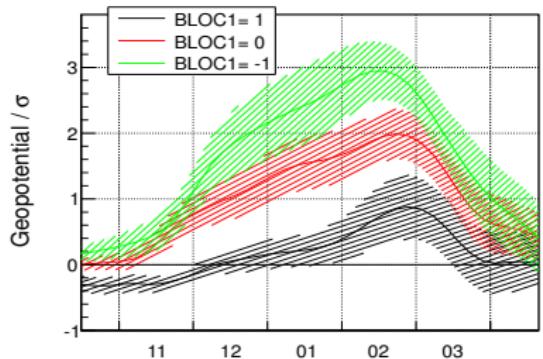
Vorhersage des Winters 2011/12

► Annahmen



Vorhersage des Winters 2011/12

► Annahmen



Zusammenfassung

- Vier unabhängige statistische Methoden (linear, nichtlinear, nichtstationär) modellieren stratosphärische Variabilität: LDA, FEM-VARX, MLP, SVM

Zusammenfassung

- Vier unabhängige statistische Methoden (linear, nichtlinear, nichtstationär) modellieren stratosphärische Variabilität: LDA, FEM-VARX, MLP, SVM
- Informationskriterien und Kreuzvalidierung bestimmen die optimalen Modellarchitekturen (Ockhams Rasiermesser)

Zusammenfassung

- Vier unabhängige statistische Methoden (linear, nichtlinear, nichtstationär) modellieren stratosphärische Variabilität: LDA, FEM-VARX, MLP, SVM
- Informationskriterien und Kreuzvalidierung bestimmen die optimalen Modellarchitekturen (Ockhams Rasiermesser)
- Ein Satz von externen Faktoren (z.B. QBO, ENSO, Solarzyklus) wird ausgenutzt, um die statistischen Modelle zu trainieren → Bestimmung der Wichtigkeit der Faktoren

Zusammenfassung

- Vier unabhängige statistische Methoden (linear, nichtlinear, nichtstationär) modellieren stratosphärische Variabilität: LDA, FEM-VARX, MLP, SVM
- Informationskriterien und Kreuzvalidierung bestimmen die optimalen Modellarchitekturen (Ockhams Rasiermesser)
- Ein Satz von externen Faktoren (z.B. QBO, ENSO, Solarzyklus) wird ausgenutzt, um die statistischen Modelle zu trainieren → Bestimmung der Wichtigkeit der Faktoren
- Schließlich kann versucht werden stratosphärische Variabilität statistisch vorherzusagen (Mustererkennung)

Zusammenfassung

- Vier unabhängige statistische Methoden (linear, nichtlinear, nichtstationär) modellieren stratosphärische Variabilität: LDA, FEM-VARX, MLP, SVM
- Informationskriterien und Kreuzvalidierung bestimmen die optimalen Modellarchitekturen (Ockhams Rasiermesser)
- Ein Satz von externen Faktoren (z.B. QBO, ENSO, Solarzyklus) wird ausgenutzt, um die statistischen Modelle zu trainieren → Bestimmung der Wichtigkeit der Faktoren
- Schließlich kann versucht werden stratosphärische Variabilität statistisch vorherzusagen (Mustererkennung)
- Drei Anwendungen:
 - Quantifizierung von natürlicher Variabilität (global)
 - Klassifizierung von Stratosphärenwärmungen
 - Vorhersage von polarer Variabilität in der Stratosphäre

Fazit

- *komplexe statist. Methoden vs. einfache lineare Methoden*

Fazit

- *komplexe statist. Methoden vs. einfache lineare Methoden*
→ Lineare Methoden sind ok für wenig training events (e.g. monatliche Daten). Komplexe Methoden sind jedoch effizienter in Bezug auf Modellierung, Vorhersage und der Gewichtung von externen Faktoren für viele training events (e.g. tägliche Daten). Sorgfältige Wahl von externen Faktoren, Zeitlichen Lags und Modellparametern.

Fazit

- *komplexe statist. Methoden vs. einfache lineare Methoden*
→ Lineare Methoden sind ok für wenig training events (e.g. monatliche Daten). Komplexe Methoden sind jedoch effizienter in Bezug auf Modellierung, Vorhersage und der Gewichtung von externen Faktoren für viele training events (e.g. tägliche Daten). Sorgfältige Wahl von externen Faktoren, Zeitlichen Lags und Modellparametern.
- *Potential der Vorhersage durch statist. Methoden*

Fazit

- *komplexe statist. Methoden vs. einfache lineare Methoden*
 - Lineare Methoden sind ok für wenig training events (e.g. monatliche Daten). Komplexe Methoden sind jedoch effizienter in Bezug auf Modellierung, Vorhersage und der Gewichtung von externen Faktoren für viele training events (e.g. tägliche Daten). Sorgfältige Wahl von externen Faktoren, Zeitlichen Lags und Modellparametern.
- *Potential der Vorhersage durch statist. Methoden*
 - Großes Potential für generelle langfristige Trends und polare Variabilität in der mittleren Stratosphäre. Vorhersage eingeschränkt durch: Interne Variabilität, Modellfehler und unzureichende externe Faktoren.

Fazit

- *komplexe statist. Methoden vs. einfache lineare Methoden*
→ Lineare Methoden sind ok für wenig training events (e.g. monatliche Daten). Komplexe Methoden sind jedoch effizienter in Bezug auf Modellierung, Vorhersage und der Gewichtung von externen Faktoren für viele training events (e.g. tägliche Daten). Sorgfältige Wahl von externen Faktoren, Zeitlichen Lags und Modellparametern.
- *Potential der Vorhersage durch statist. Methoden*
→ Großes Potential für generelle langfristige Trends und polare Variabilität in der mittleren Stratosphäre. Vorhersage eingeschränkt durch: Interne Variabilität, Modellfehler und unzureichende externe Faktoren.
- *statist. Methode prädestiniert für stratosphärische Variabilität*

Fazit

- *komplexe statist. Methoden vs. einfache lineare Methoden*
→ Lineare Methoden sind ok für wenig training events (e.g. monatliche Daten). Komplexe Methoden sind jedoch effizienter in Bezug auf Modellierung, Vorhersage und der Gewichtung von externen Faktoren für viele training events (e.g. tägliche Daten). Sorgfältige Wahl von externen Faktoren, Zeitlichen Lags und Modellparametern.
- *Potential der Vorhersage durch statist. Methoden*
→ Großes Potential für generelle langfristige Trends und polare Variabilität in der mittleren Stratosphäre. Vorhersage eingeschränkt durch: Interne Variabilität, Modellfehler und unzureichende externe Faktoren.
- *statist. Methode prädestiniert für stratosphärische Variabilität*
→ Die “beste” Methode existiert nicht. Von den Erfahrungen gesammelt in dieser Arbeit: LDA ist robust für monatliche Modellierung und Vorhersage. Auf der täglichen Skala liefern FEM-VARX und MLP die besten Ergebnisse.

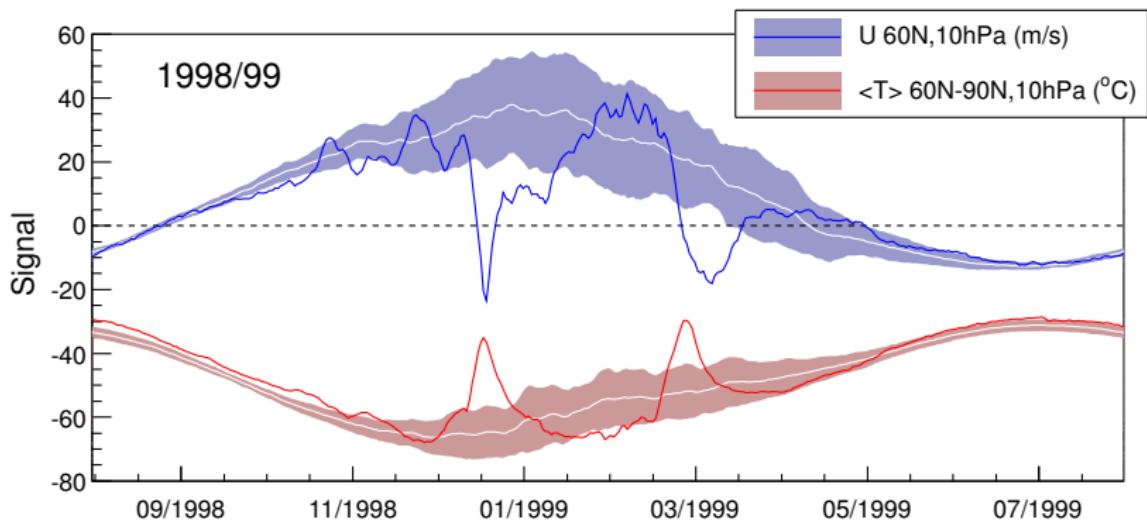
Danke für Eure Aufmerksamkeit!

Ausblick

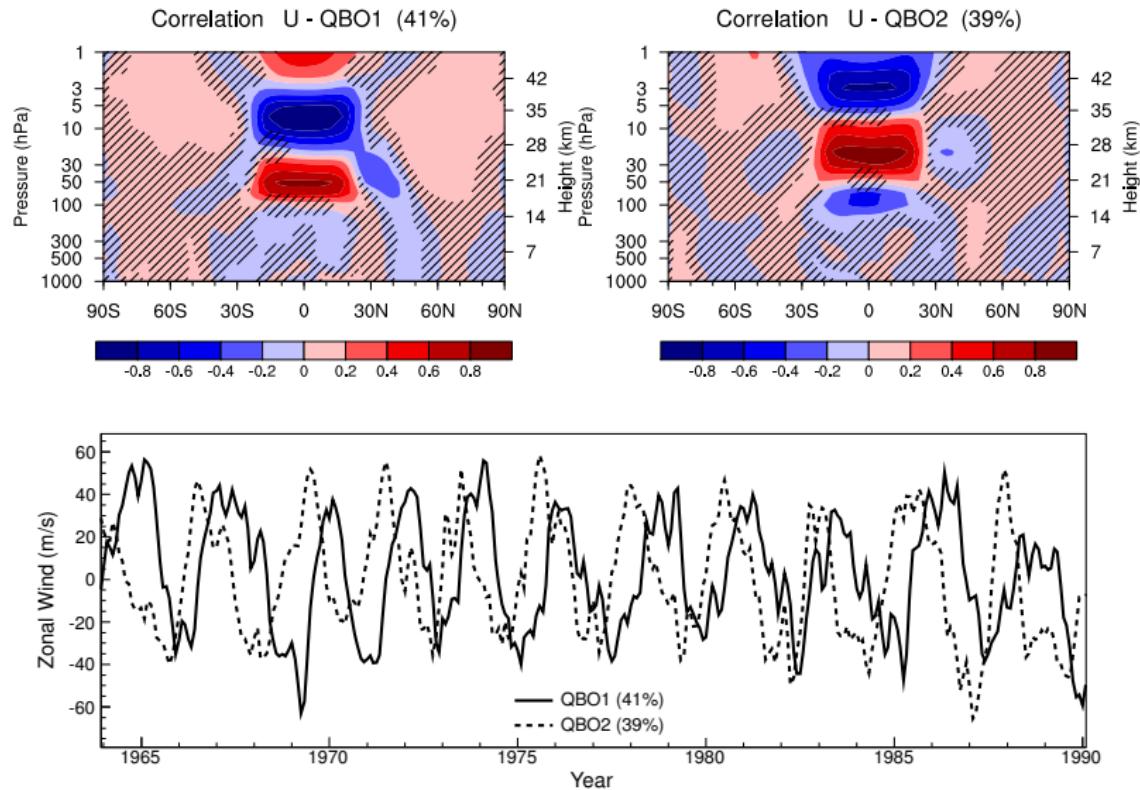
- Modellauswahl: Gleichzeitige Optimierung von Anzahl der externen Faktoren *und* interne Modellarchitektur
- Zeitliche Lags: Optimierung pro statistischer Methode
- Komplementierung von Ensemble- Vorhersagen auf kurzen und langen Zeitskalen mit statistischen Methoden
- Drei Hauptbereiche:
 - Quantifizierung der Wichtigkeit von externen Faktoren
 - Verstehen von nichtlinearen Zusammenhängen
 - Vorhersage auf verschiedenen Zeitskalen

⇒ Großes Potential für zukünftliche, statistische Modellierung und Vorhersage von stratosphärischer Variabilität

Zwei typische Major Warmings

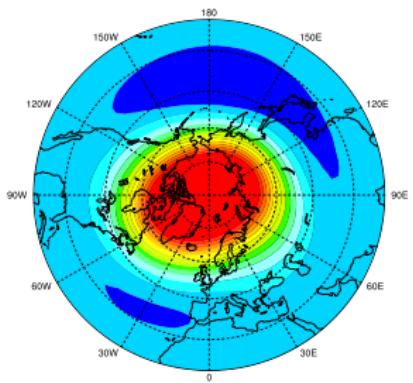


Quasi-Biennial Oscillation

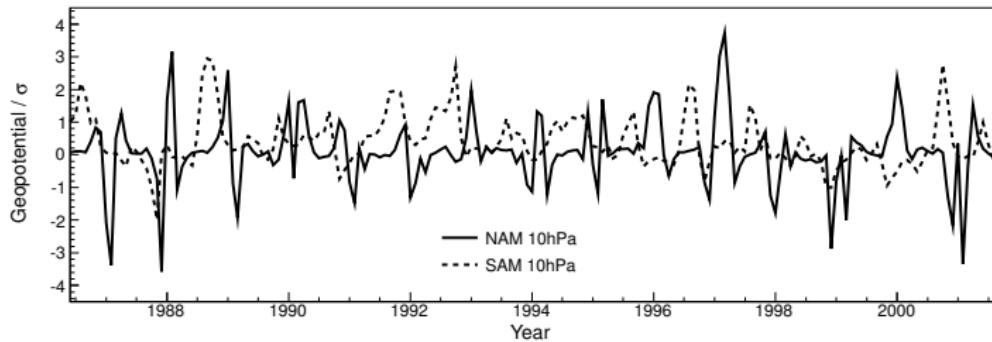
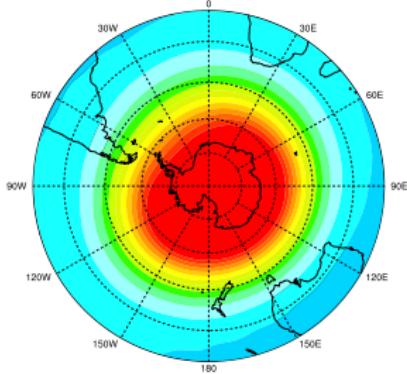


NAM und SAM

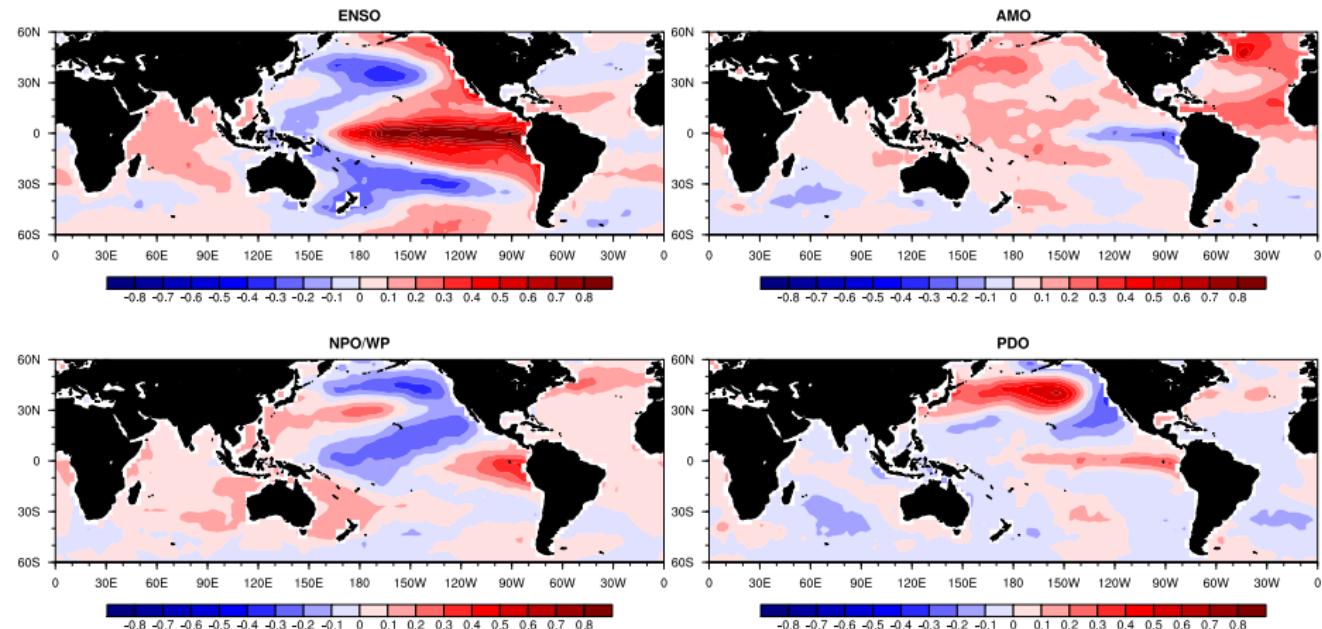
NAM 10hPa (50%)



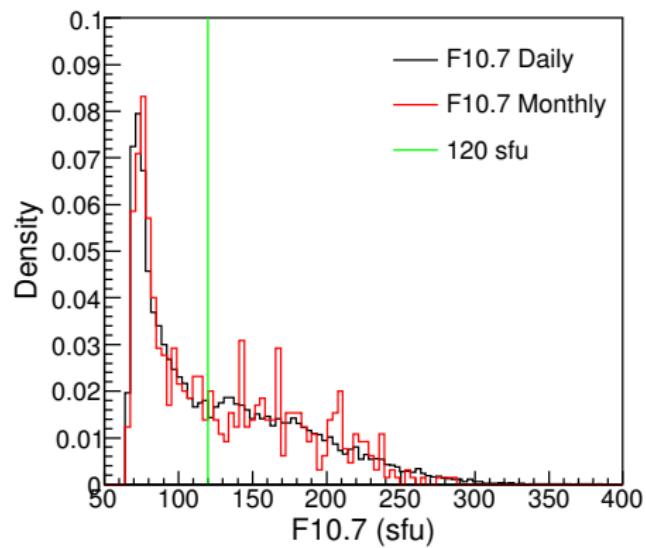
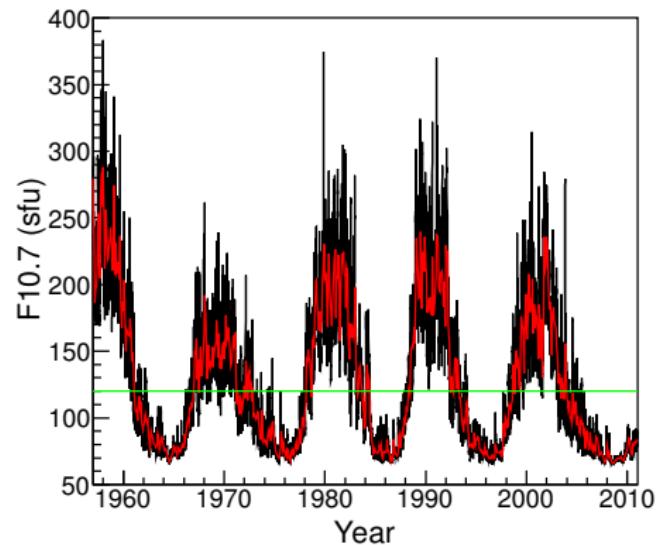
SAM 10hPa (55%)



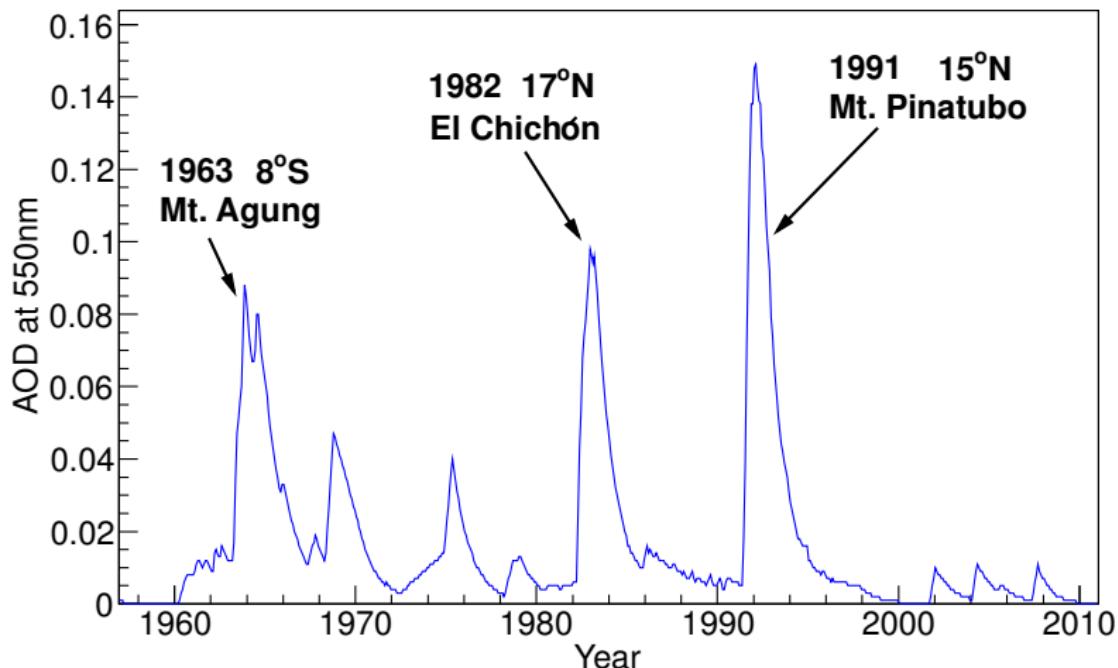
Variabilität in SSTs



11-jähriger Solarzyklus (F10.7)

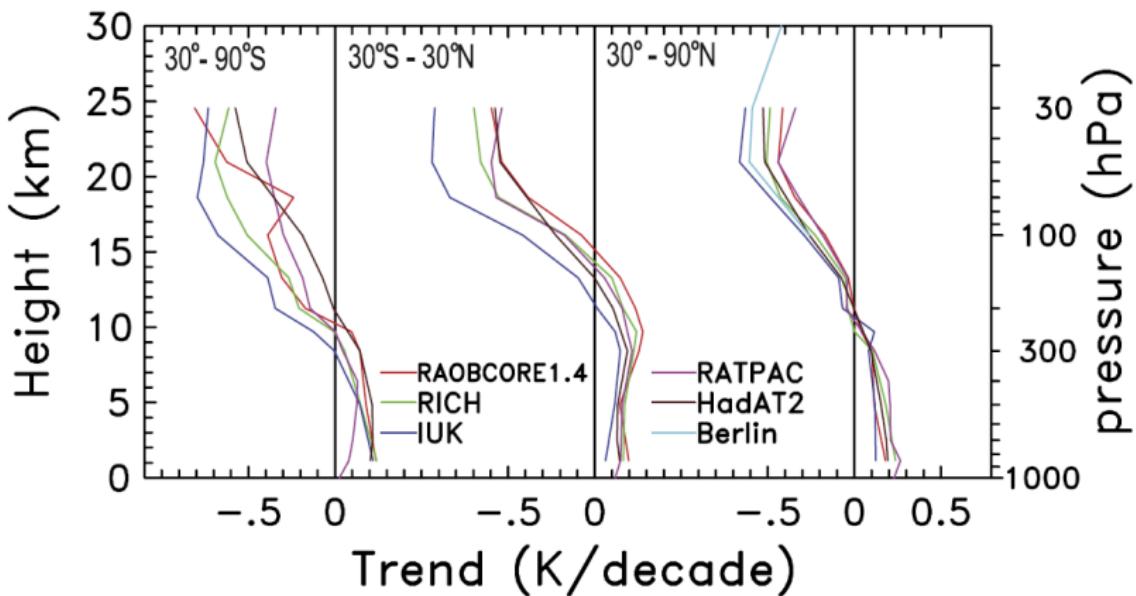


Vulkanische Eruptionen (AOD)



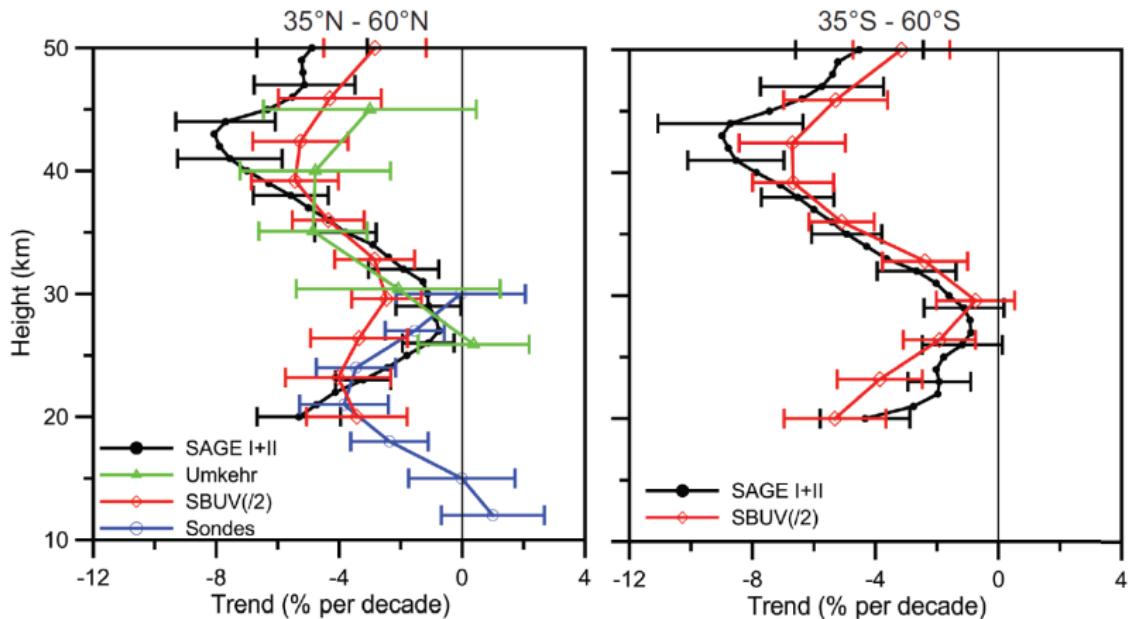
Temperatur Trends

1958–2007



[Randel et al., 2009]

Ozon Trends



[Randel and Thompson, 2011]

Principal Component Analysis

$$\mathbf{P} = \mathbf{X} \cdot \mathbf{U} \in \mathbb{R}^{m \times k}$$

Eigenproblem:

$$\mathbf{C} \cdot \mathbf{U} = \mathbf{U} \cdot \Lambda$$

mit $\mathbf{C} = \frac{1}{m} \mathbf{X} \mathbf{X}^T$.

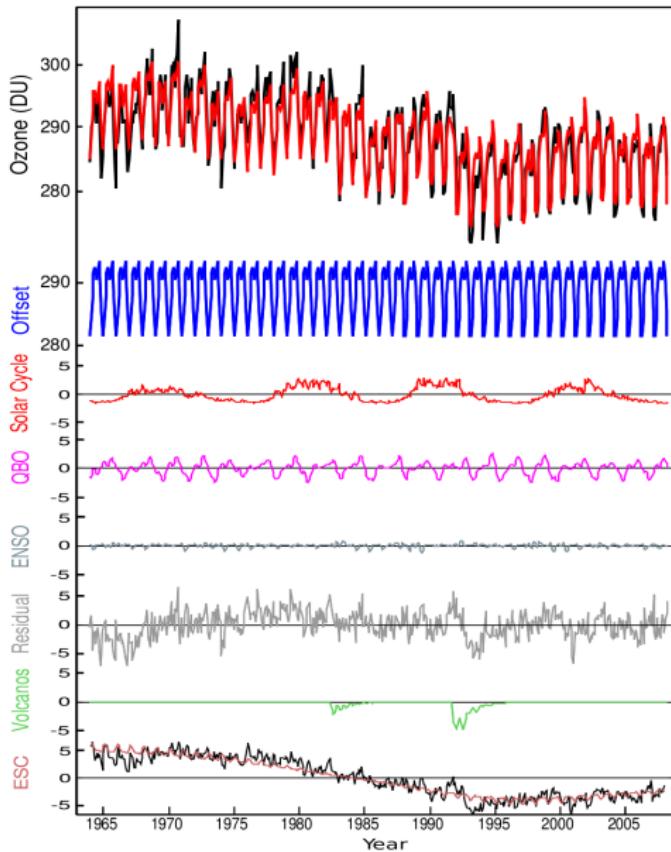
Energie der Eigenwerte:

$$E = \sum_{i=1}^k \lambda_i$$

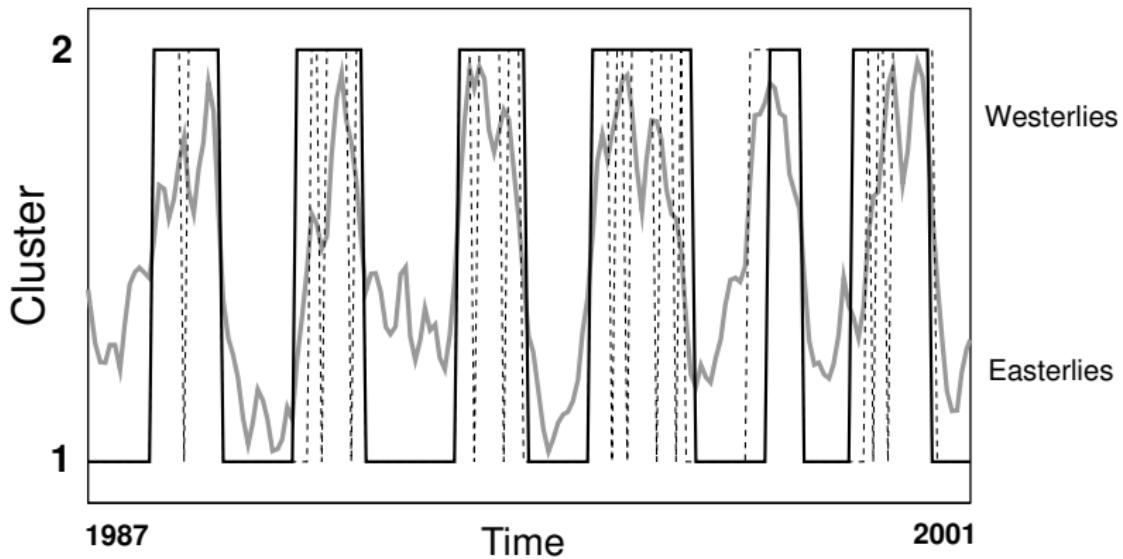
Faustformel [North et al., 1982]:

$$\Delta \lambda_i = \lambda_i \cdot \sqrt{\frac{2}{m}}$$

Ein LDA Beispiel

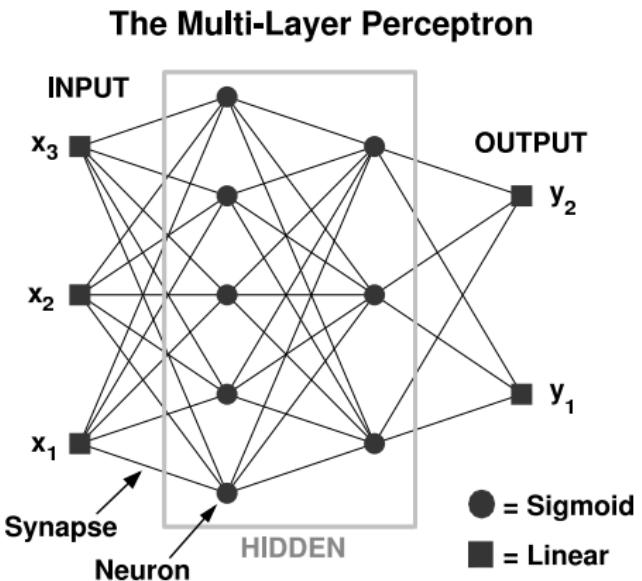
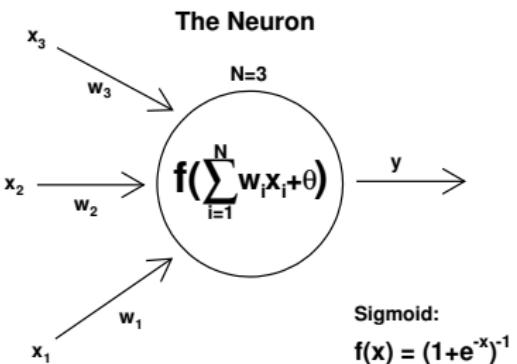


FEM-VARX

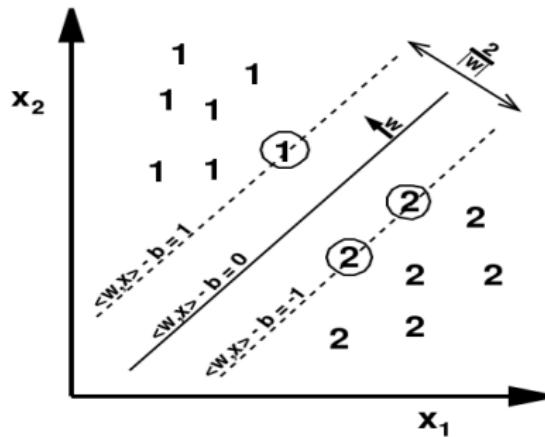


$$\sum_{t=1}^{T-1} |\gamma_i(t+1) - \gamma_i(t)| \leq C \quad \mathbf{y}_{t,i}^* = \mu^i + \mathbf{B}^i \mathbf{x}_t + \sum_{q=1}^m \mathbf{A}_q^i \mathbf{y}_{t-q}$$

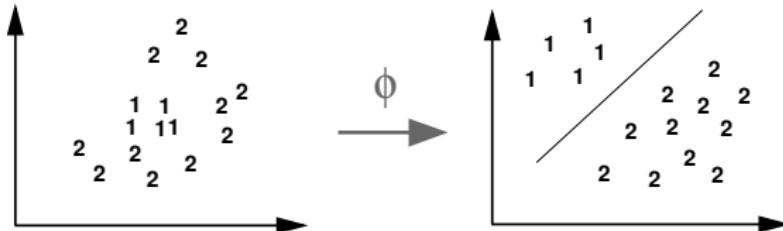
Multi-Layer Perceptron



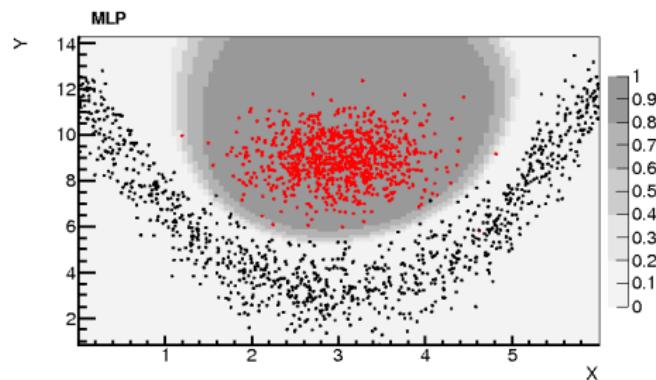
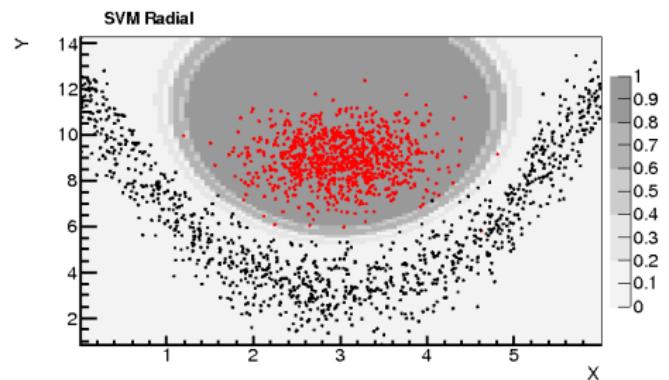
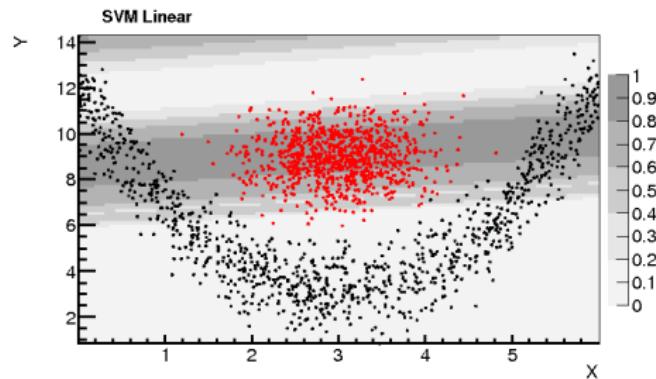
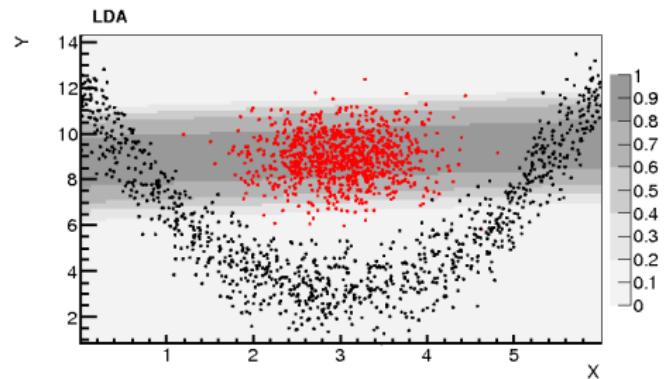
Support Vector Machine



The Kernel Trick



Nichtlineares Beispiel zur Klassifizierung



Informationskriterien

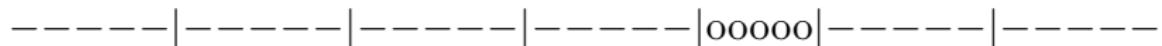
$$\text{BIC} = n \ln(\sigma_e^2) + \ln(n)k$$

$$\text{AIC} = n \ln(\sigma_e^2) + 2k$$

- n - Anzahl der Trainingsevents
- k - Anzahl der Modellparameter
- σ_e - Standardabweichung des Residuums

Kreuzvalidierung

Einteilung der Zeitreihe in z.B. 7 Bereiche:



- Training mit 6 zusammenhängenden Bereichen
- Hindcast auf dem ausgelassenen Bereich
- Wiederholung für alle Bereiche
- Addition der Hindcast-Fehler

→ das Modell mit dem kleinsten Fehler ist das optimale Modell

Mittelung der Modelle

Modellmittel:

$$\Theta = \sum_{i=1}^n \omega_i \Theta_i$$

Fehler des Mittels:

$$\sigma_\Theta = \sqrt{\sum_{i=1}^n \omega_i (\sigma_i^2 + \beta_i^2)}$$

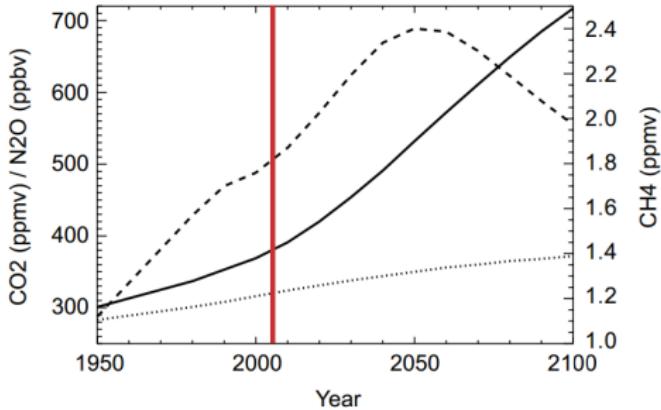
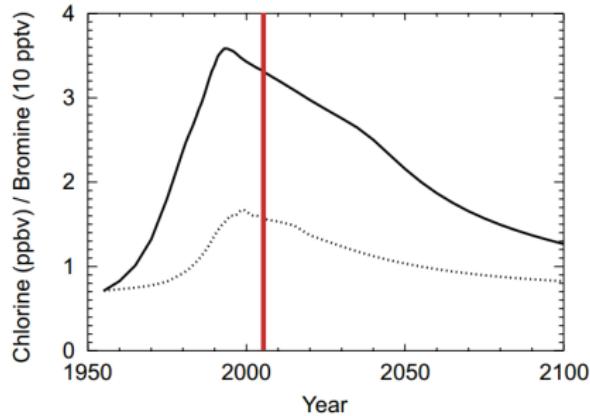
mit $\beta_i = \Theta_i - \Theta$.

[Turkheimer et al., 2003]

Genereller Vergleich der Methoden

Method	LDA	FEM-VARX	MLP	SVM
Nonlinear built-in	no	no	yes	yes
Nonstationary built-in	no	yes	no	no
Multivariate output	no	yes	yes	no
Unique solution	yes	no	no	yes
Regression	yes	yes	yes	yes
Classification	yes	no	yes	yes
Supervised learning	yes	yes	yes	yes
Unsupervised learning	no	yes	yes	yes
Data clustering	no	yes	yes	yes
Time for training (s)	$\mathcal{O}(1)$	$\mathcal{O}(100)$	$\mathcal{O}(100)$	$\mathcal{O}(10)$
Information criteria	yes	yes	yes	no
Cross-validation	yes	no	yes	yes

CCMVal-2 Anthropogenic Forcings



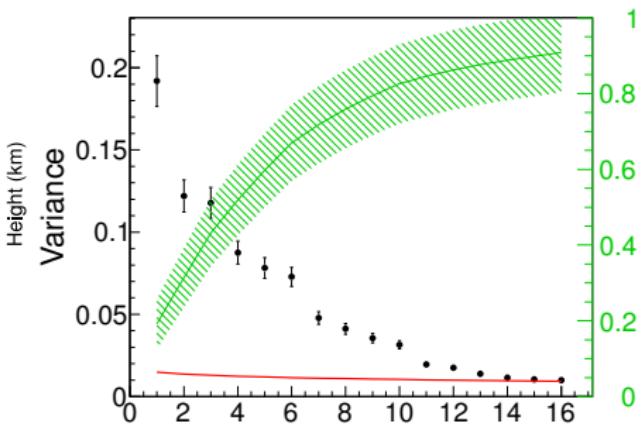
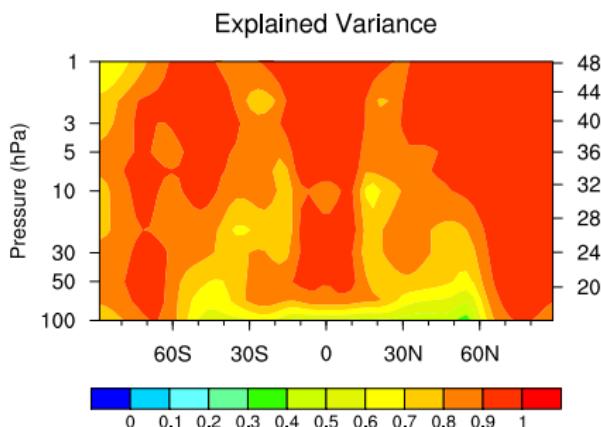
Left: Surface total chlorine (solid) and total bromine (dotted) as defined in the A1 scenario [WMO, 2007].

Right: Surface CO₂ (solid), N₂O (dotted), and CH₄ (dashed) as defined in the A1b scenario [IPCC, 2001].

Bestimmung von natürlicher Variabilität

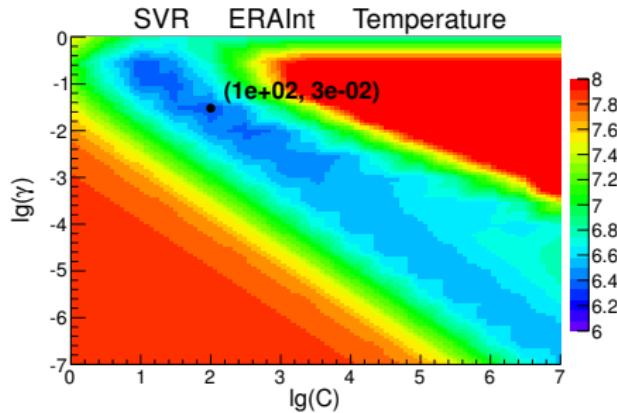
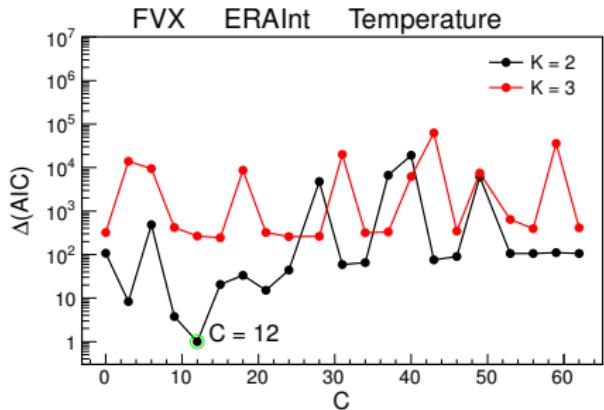
> PCA Dimensionsreduktion bei 90% Varianzerhaltung <

	ERAInt	MERRA	RANDEL	NIWA	EMAC	WACCM	MRI
T	16	15	n/a	n/a	10	10	11
O ₃	n/a	n/a	9	7	10	17	9



Bestimmung von natürlicher Variabilität

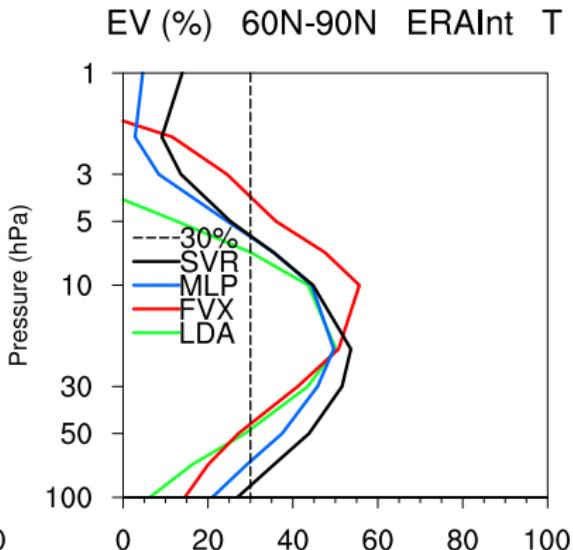
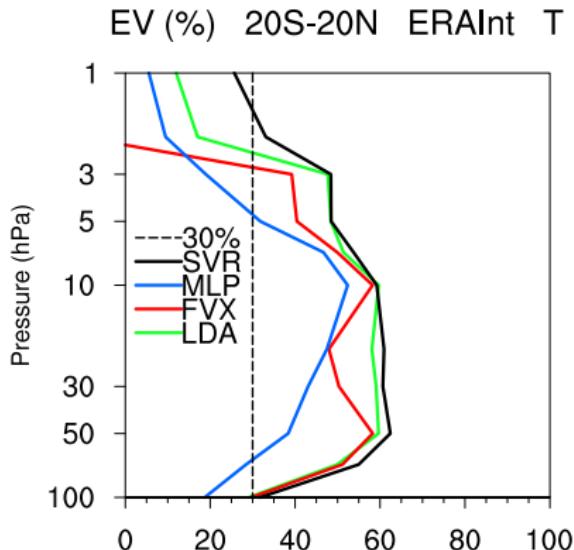
> Modellauswahl <



	FVX	MLP	SVR	T	FVX	MLP	SVR	O ₃
ERAInt	2, 12	8, 0	$10^2, 3 \cdot 10^{-2}$					
MERRA	2, 9	5, 0	$3 \cdot 10^3, 3 \cdot 10^{-3}$					
RANDEL					2, 28	8, 0	$10^5, 3 \cdot 10^{-2}$	
NIWA					2, 6	6, 7	$10^4, 10^{-1}$	
EMAC	2, 21	5, 0	$10^4, 3 \cdot 10^{-3}$		2, 37	6, 6	$10^5, 10^{-2}$	
WACCM	2, 12	6, 0	$10^3, 10^{-2}$		2, 9	5, 7	$10^4, 10^{-1}$	
MRI	2, 21	5, 0	$10^4, 3 \cdot 10^{-3}$		2, 3	5, 0	$3 \cdot 10^4, 3 \cdot 10^{-2}$	

Bestimmung von natürlicher Variabilität

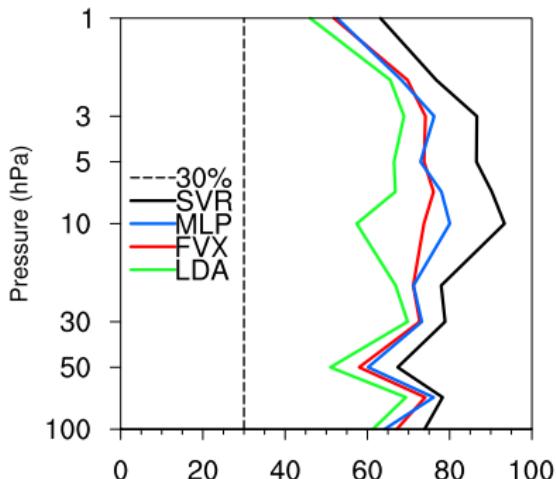
> Regressionsgüte am Beispiel (T) <



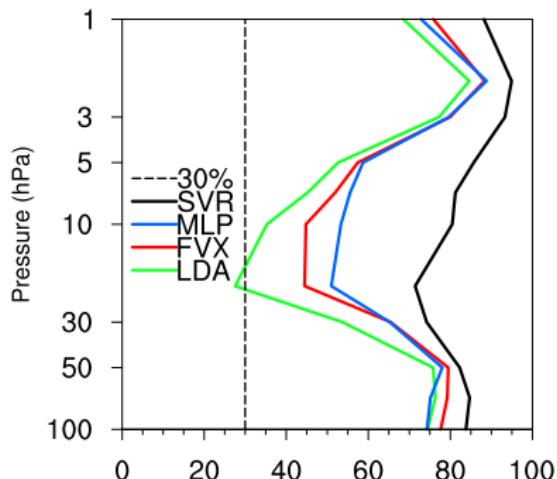
Bestimmung von natürlicher Variabilität

> Regressionsgüte am Beispiel (O_3) <

EV (%) 20S-20N RANDEL O₃



EV (%) 60N-90N RANDEL O₃



Bestimmung von natürlicher Variabilität

> Regressionsgüte in der Zusammenfassung <

Erklärte Varianz: $EV = 1 - \sigma_e^2 / \sigma_y^2$

	LDA	FVX	MLP	SVR	T	LDA	FVX	MLP	SVR	O ₃
ERAInt	29	28	23	39						
MERRA	27	26	28	37						
RANDEL						55	64	65	79	
NIWA						53	63	68	81	
EMAC	30	31	35	42		50	53	48	63	
WACCM	29	26	23	44		49	54	46	78	
MRI	14	18	21	35		65	68	63	77	
Mean	26±3	26±2	26±2	39±1		54±3	60±3	58±4	76±3	

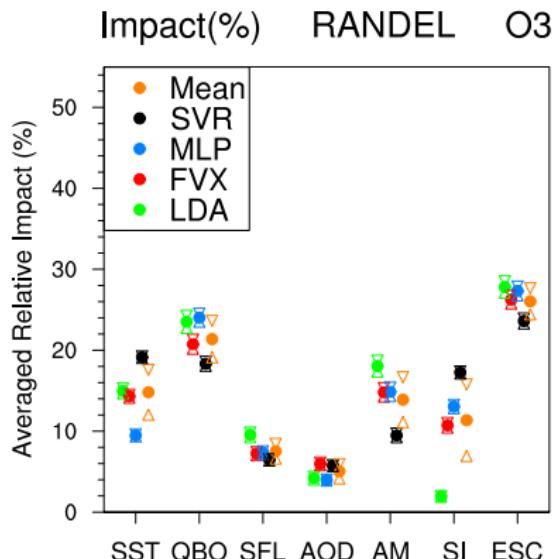
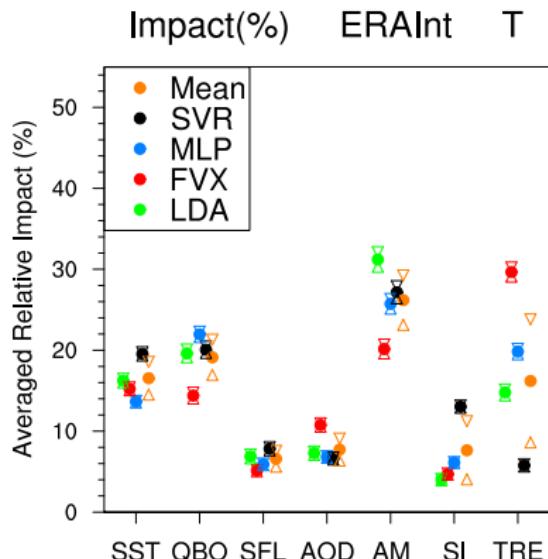
Bestimmung von natürlicher Variabilität

> Individuelle Wichtigkeit auf die STMs <

$$\text{Impact}_k = \sigma(Y - Y^k) \quad (\approx |\beta_k| \sigma(x_k))_{\text{LDA}}$$

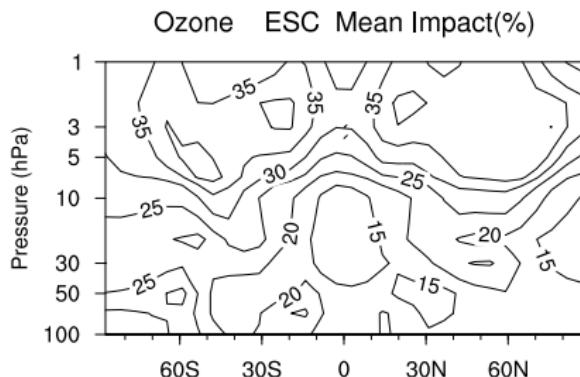
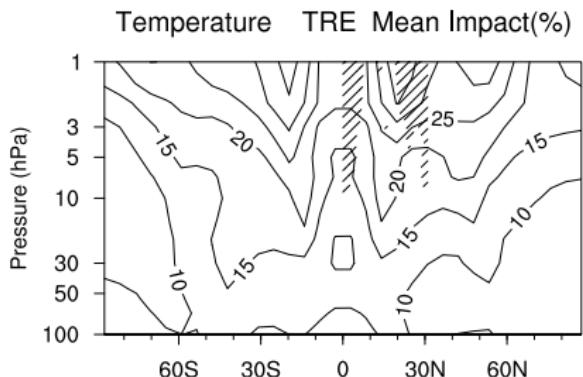
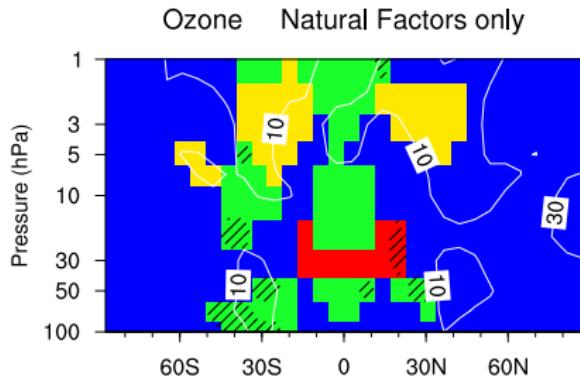
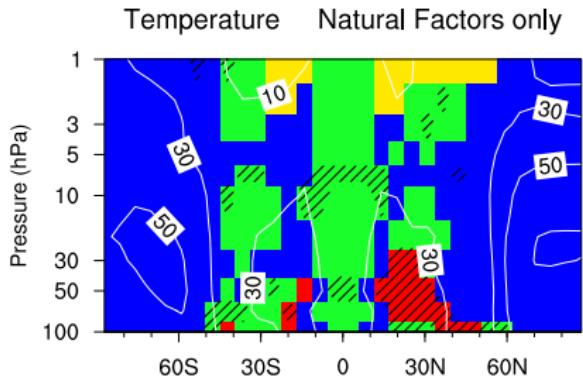
Y - Originale Antwort

Y^k - Antwort für Faktor k am Median



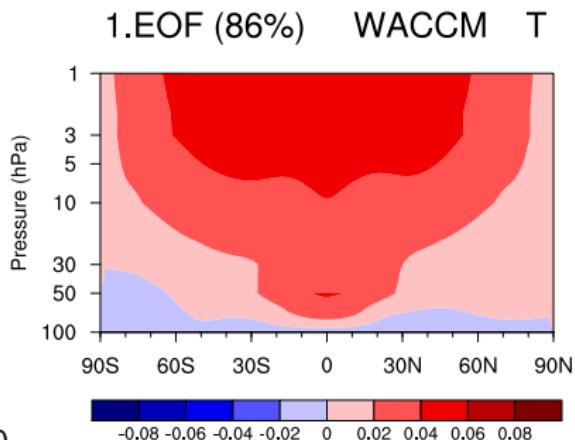
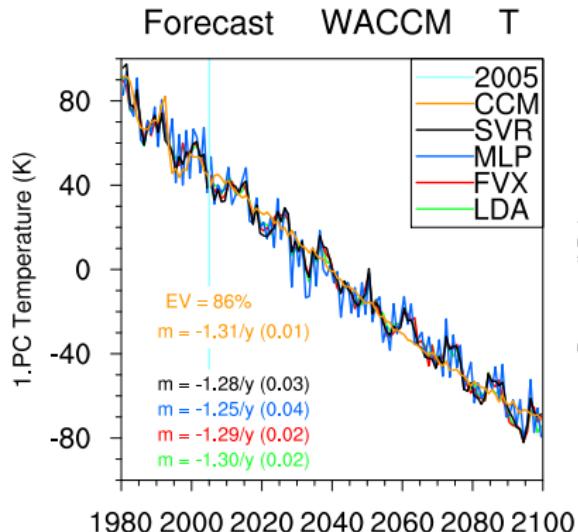
Bestimmung von natürlicher Variabilität

> Regionale Wichtigkeit der Faktoren <



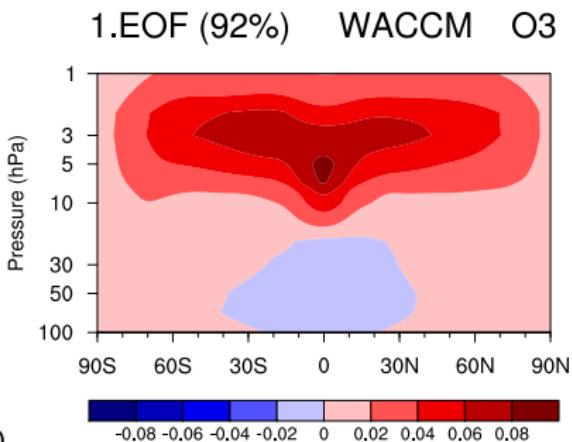
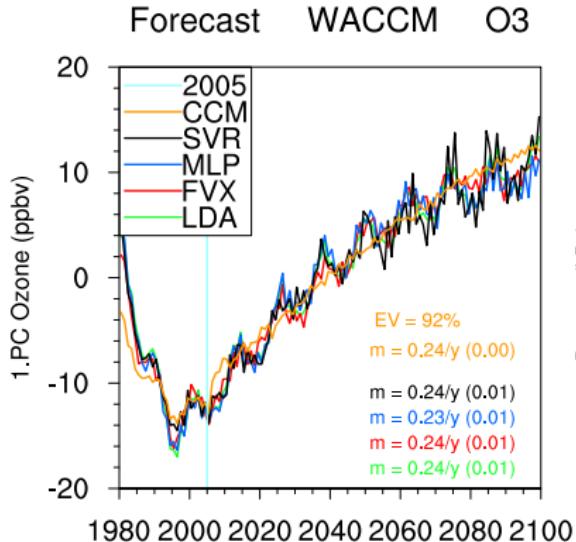
Bestimmung von natürlicher Variabilität

> Langfristige Vorhersage (T) <



Bestimmung von natürlicher Variabilität

> Langfristige Vorhersage (O_3) <



Klassifizierung von Stratosphärenerwärmungen

> Trainingsdaten <

$$W_t^{\text{dis}} := \begin{cases} 1 & \text{PC1}_t > 1 \\ 0 & \text{otherwise} \end{cases}$$

$$W_t^{\text{final}} := \begin{cases} 1 & W_t^{\text{dis}} = 1 \quad \wedge \quad \overline{T}_t^{30} \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

$$W_t^{\text{major}} := \begin{cases} 1 & W_t^{\text{dis}} = 1 \quad \wedge \quad W_t^{\text{final}} = 0 \quad \wedge \quad U_t^{10,60N} < 0 \\ 0 & \text{otherwise} \end{cases}$$

$$W_t^{\text{minor}} := \begin{cases} 1 & W_t^{\text{dis}} = 1 \quad \wedge \quad W_t^{\text{final}} = 0 \quad \wedge \quad W_t^{\text{major}} = 0 \\ 0 & \text{otherwise} \end{cases}$$

$$W_t^{\text{major}} + W_t^{\text{minor}} + W_t^{\text{final}} + W_t^{\text{undis}} = 1 \quad \forall t$$

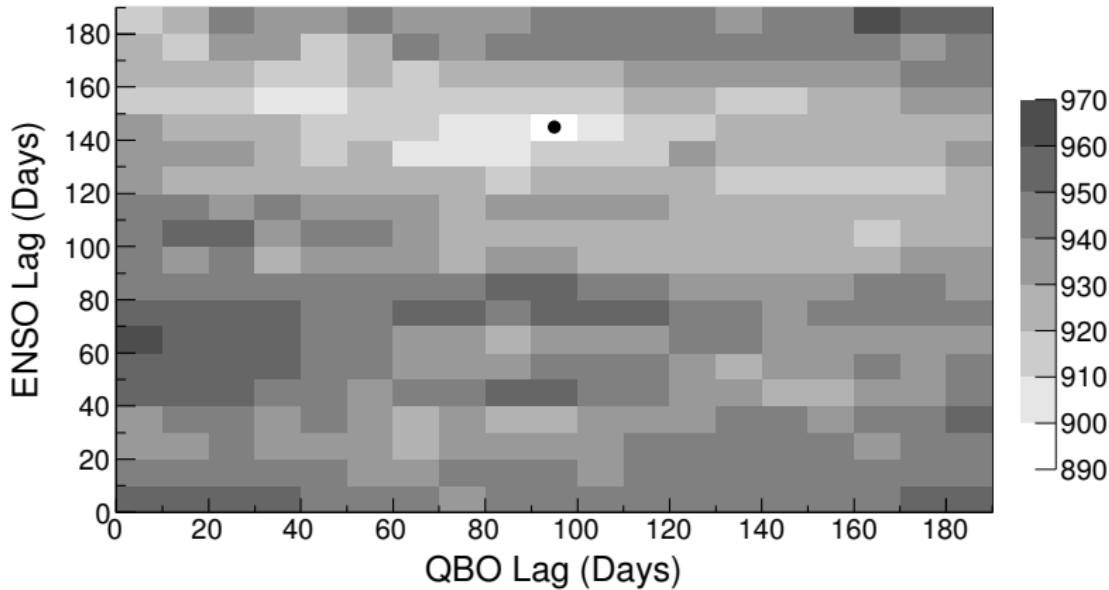
Klassifizierung von Stratosphärenerwärmungen

> Korrelationen der Input Faktoren <

SC	-6.7	5.5	0.7	-1.4	100
ENSO	-1.3	5.2	6.1	100	-1.4
QBO	-2.6	-1.7	100	6.1	0.7
PC1	-0.2	100	-1.7	5.2	5.5
\overline{T}^{30}	100	-0.2	-2.6	-1.3	-6.7
	\overline{T}^{30}	PC1	QBO	ENSO	SC

Klassifizierung von Stratosphärenerwärmungen

> Zeitliche Lags <



Klassifizierung von Stratosphärenwärmungen

> Performance der drei Methoden <

	S			ε_S			I_{ROC}		
Class	LDA	LSVM	MLP	LDA	LSVM	MLP	LDA	LSVM	MLP
Major	0.857	0.814	<u>0.864</u>	0.490	0.542	<u>0.945</u>	0.984	0.981	<u>0.987</u>
Minor	0.831	0.733	<u>0.851</u>	0.080	0.107	<u>0.935</u>	0.963	0.941	<u>0.983</u>
Final	0.822	0.527	<u>0.862</u>	0.044	0.095	<u>0.950</u>	0.953	0.801	<u>0.997</u>
Undisturbed	0.898	<u>0.909</u>	0.882	0.869	<u>0.985</u>	0.981	0.995	0.998	<u>0.999</u>

$$S = \frac{1}{2} \int_{-\infty}^{\infty} \frac{(y_S(x) - y_B(x))^2}{y_S(x) + y_B(x)} dx$$

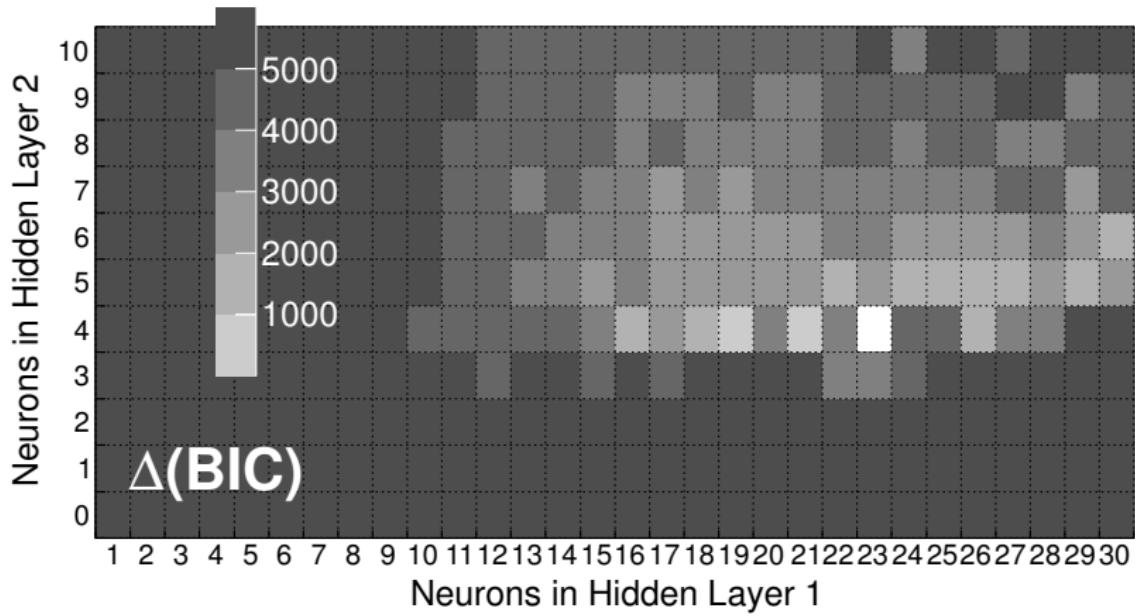
$$\varepsilon_S = \int_a^{\infty} y_S(x) dx$$

$$\text{mit } \varepsilon_B = \int_a^{\infty} y_B(x) dx = 0.01$$

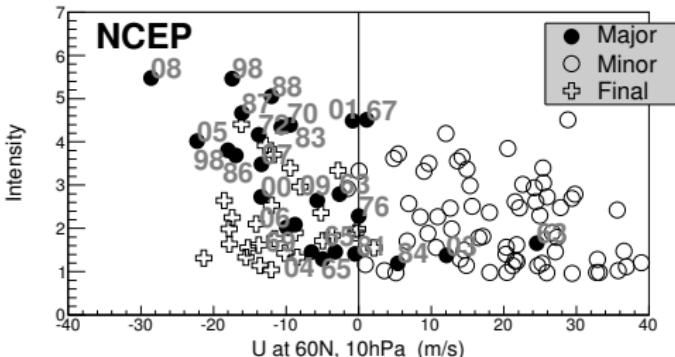
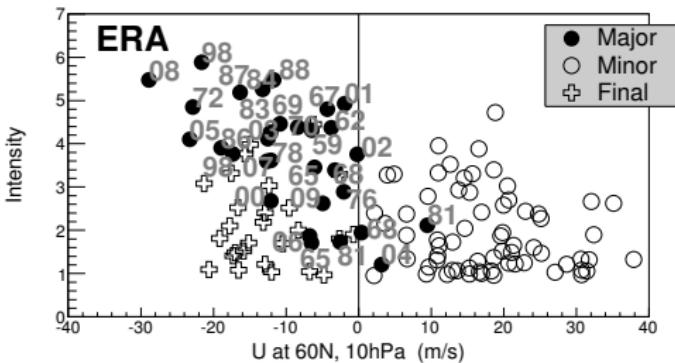
$$I_{ROC} = \int_0^1 (1 - \varepsilon_B) d\varepsilon_S$$

Klassifizierung von Stratosphärenerwärmungen

> Optimales Modell <

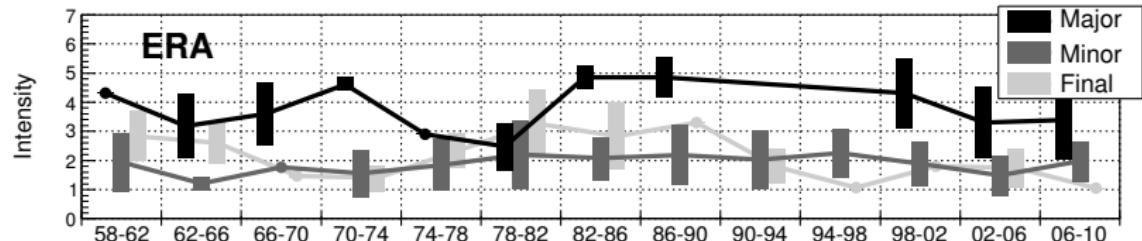
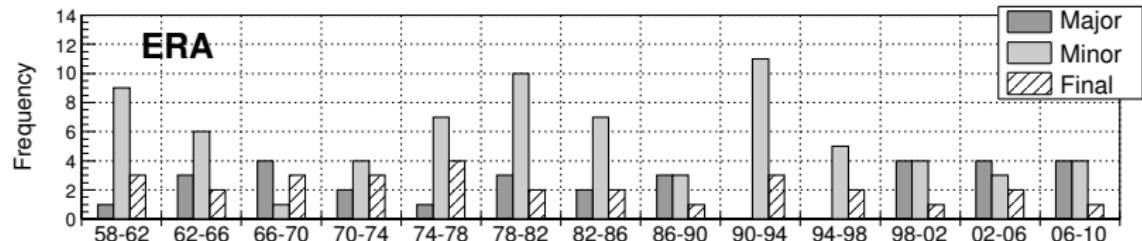


Klassifizierung von Stratosphärenerwärmungen > Windumkehr <



Klassifizierung von Stratosphärenerwärmungen

> Verteilung im rezenten Klima <



Klassifizierung von Stratosphärenerwärmungen

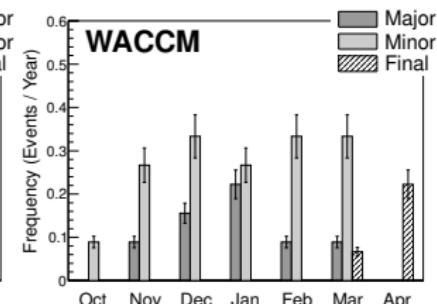
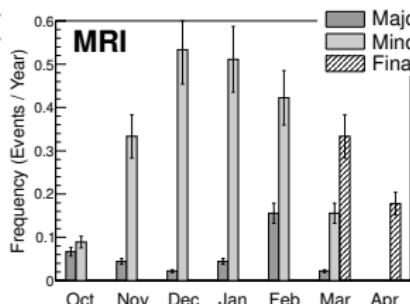
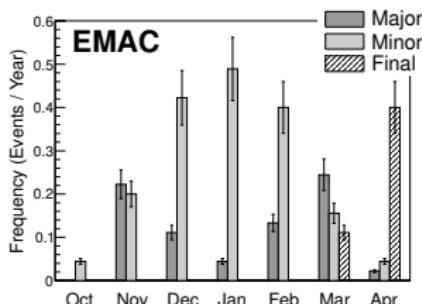
> Intensität und Dauer <

Data	Class	Intensity	Duration	Correlation
ERA	Major	3.7 (1.2)	23.0 (10.7)	0.61
	Minor	1.9 (0.9)	8.4 (8.3)	0.75
	Final	2.2 (1.0)	20.1 (10.9)	0.67
NCEP	Major	3.2 (1.4)	16.7 (12.3)	0.53
	Minor	2.1 (1.0)	8.9 (10.5)	0.52
	Final	2.2 (0.9)	20.2 (10.5)	0.41

Klassifizierung von Stratosphärenerwärmungen

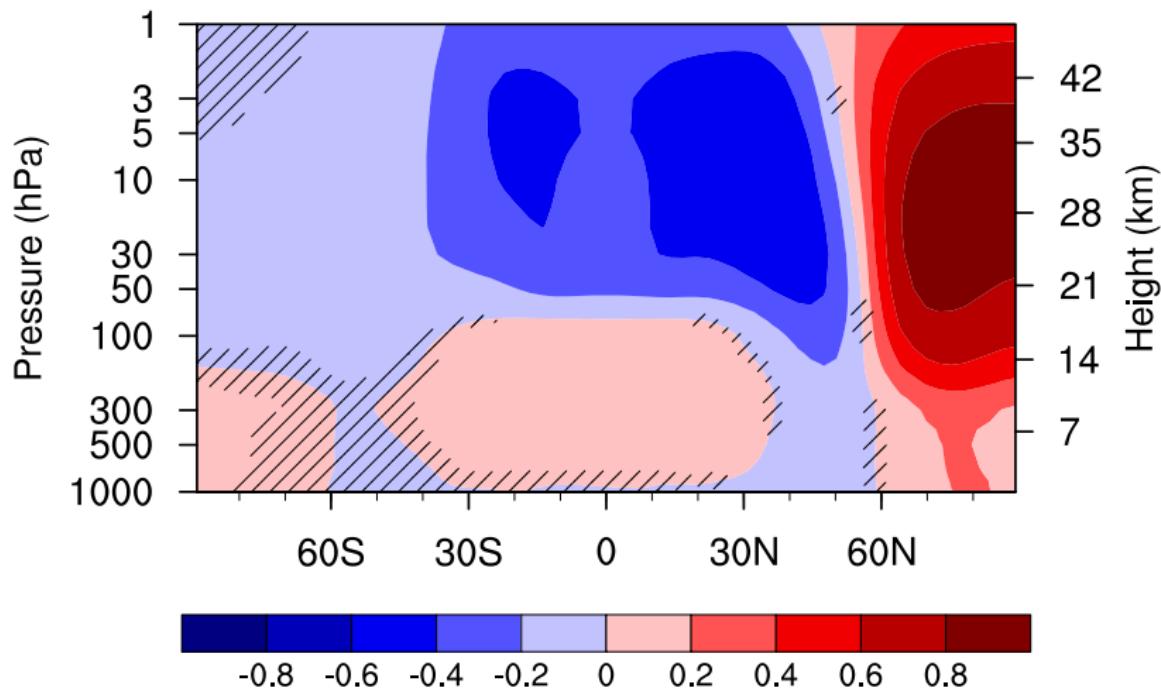
> Erwärmungen in drei CCMs <

Data	Major	Minor	Final	Total
EMAC	0.8 (0.1)	1.8 (0.3)	0.5 (0.1)	3.0 (0.4)
MRI	0.4 (0.1)	2.0 (0.3)	0.5 (0.1)	2.9 (0.4)
WACCM	0.6 (0.1)	1.6 (0.2)	0.3 (0.1)	2.6 (0.4)



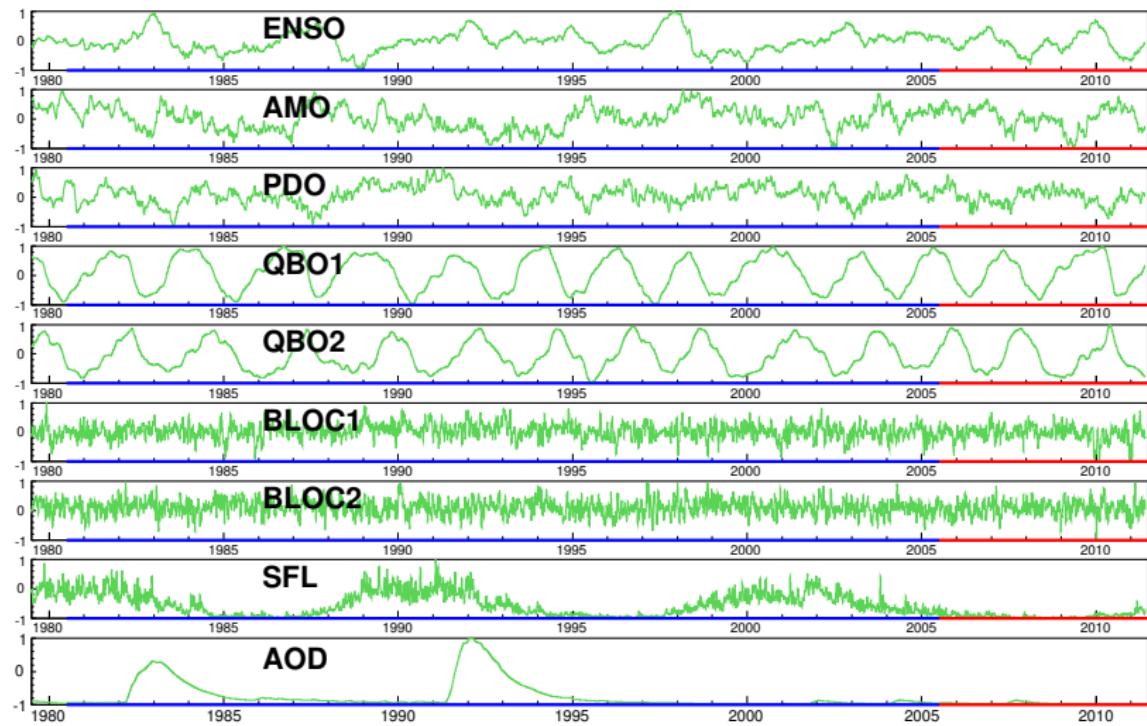
Vorhersage von polarer Variabilität

Correlation Z - NAM(Z)



Vorhersage von polarer Variabilität

> Externe Faktoren <



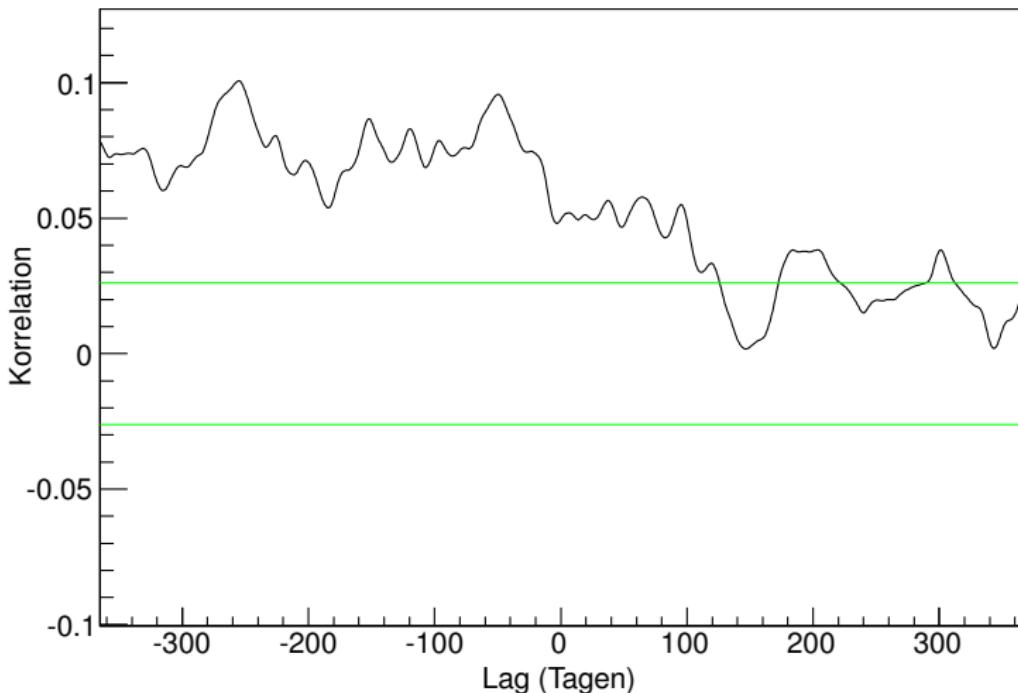
Vorhersage von polarer Variabilität

> Zeitliche Lags in Tagen <

Faktor	Geopotential	Temperatur
ENSO	96	82
AMO	8	185
PDO	0	0
QBO1	173	137
QBO2	0	264
BLOC1	0	0
BLOC2	0	0
SFL	0	50
AOD	0	0

Vorhersage von polarer Variabilität

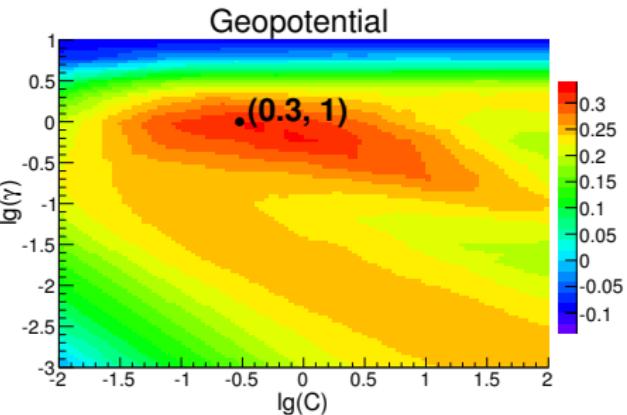
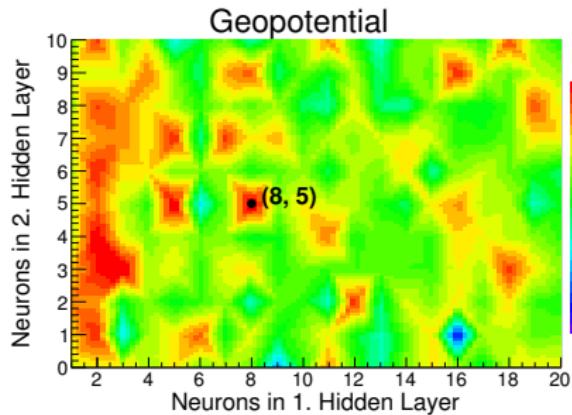
> SFL Lead-Lag Correlation <



Vorhersage von polarer Variabilität

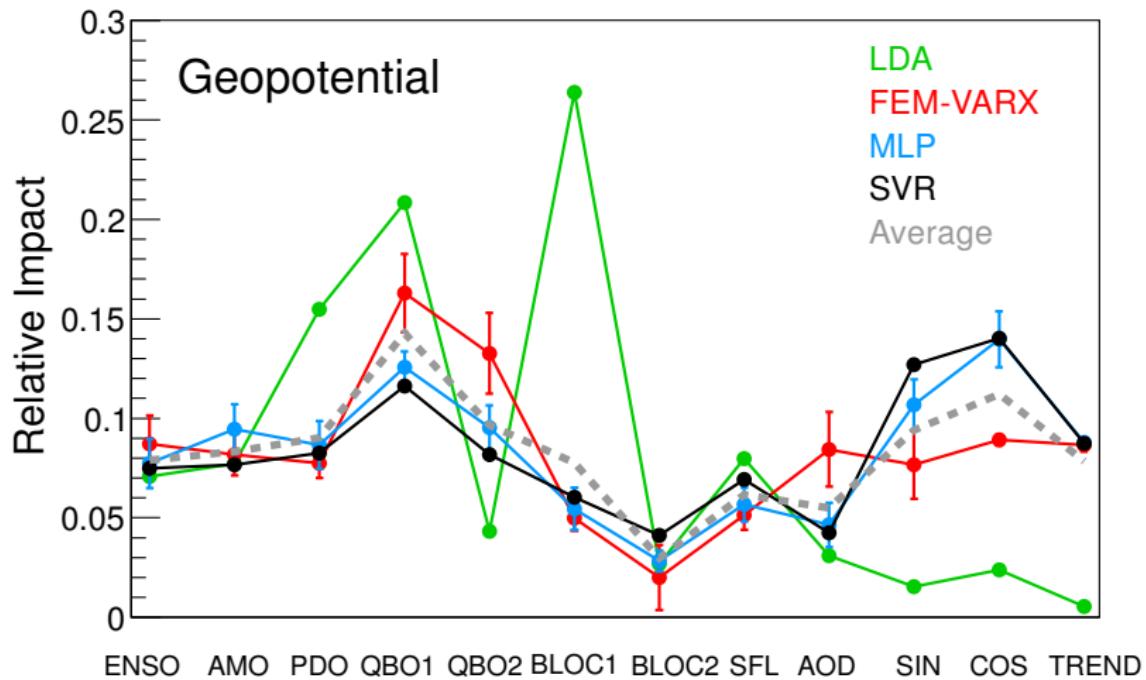
> Optimales Modell <

Modell	Geopotential	Temperatur
FEM-VARX	5, 146	5, 112
MLP	8, 5	3, 0
SVR	0.3, 1	0.3, 0.2



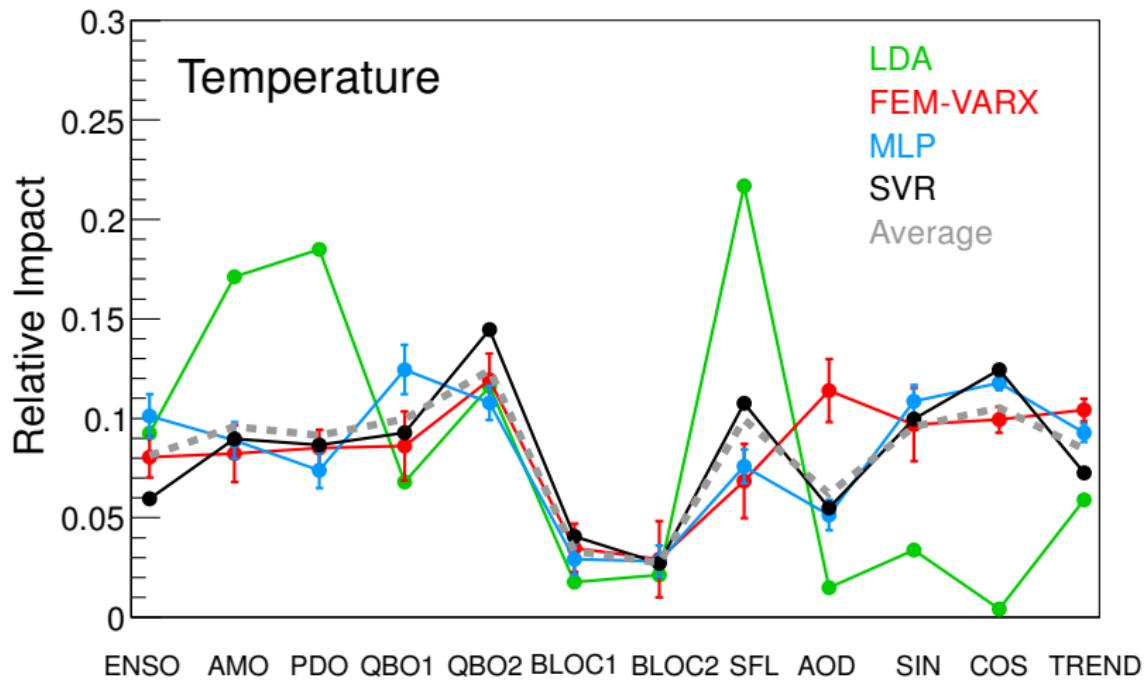
Vorhersage von polarer Variabilität

> Einfluss der Faktoren auf Geopotential <



Vorhersage von polarer Variabilität

> Einfluss der Faktoren auf Temperatur <



Vorhersage von polarer Variabilität

> Annahmen für den Winter 2011/12 <

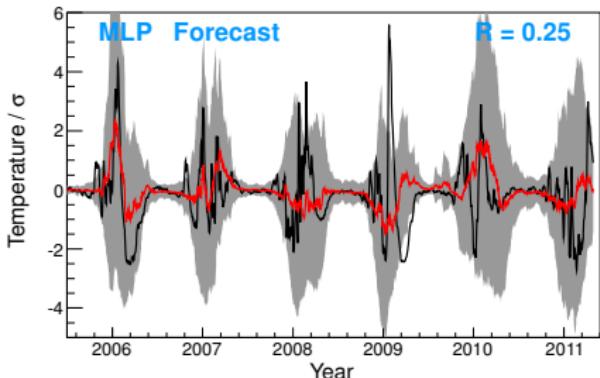
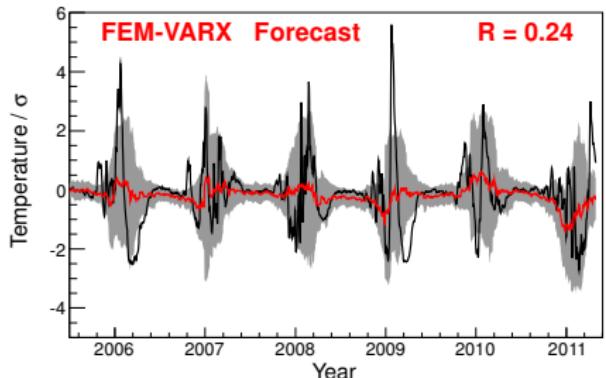
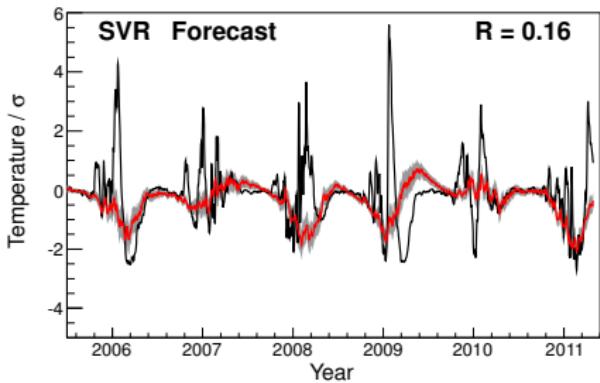
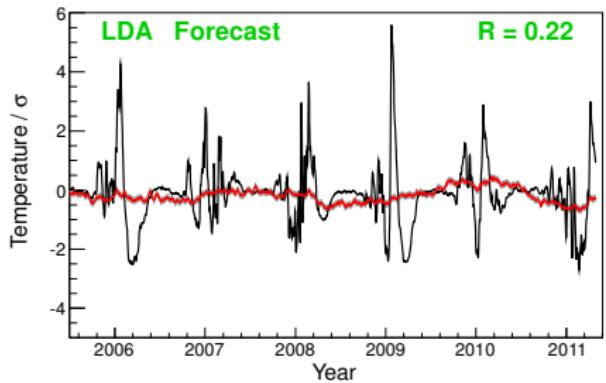
NOAA: <http://www.cpc.ncep.noaa.gov>

Faktor	Wert	Quelle
ENSO	-0.5	NOAA
AMO	-0.3	NOAA
PDO	-0.5	NOAA
QBO1	0.8	Periode
QBO2	0	Periode
BLOC2	0	Unwichtig
SFL	-0.5	NOAA
AOD	-1	Nicht vorhersagbar
Trend	1	Letzter Wert

→ Variierung von SIN,COS und BLOC1

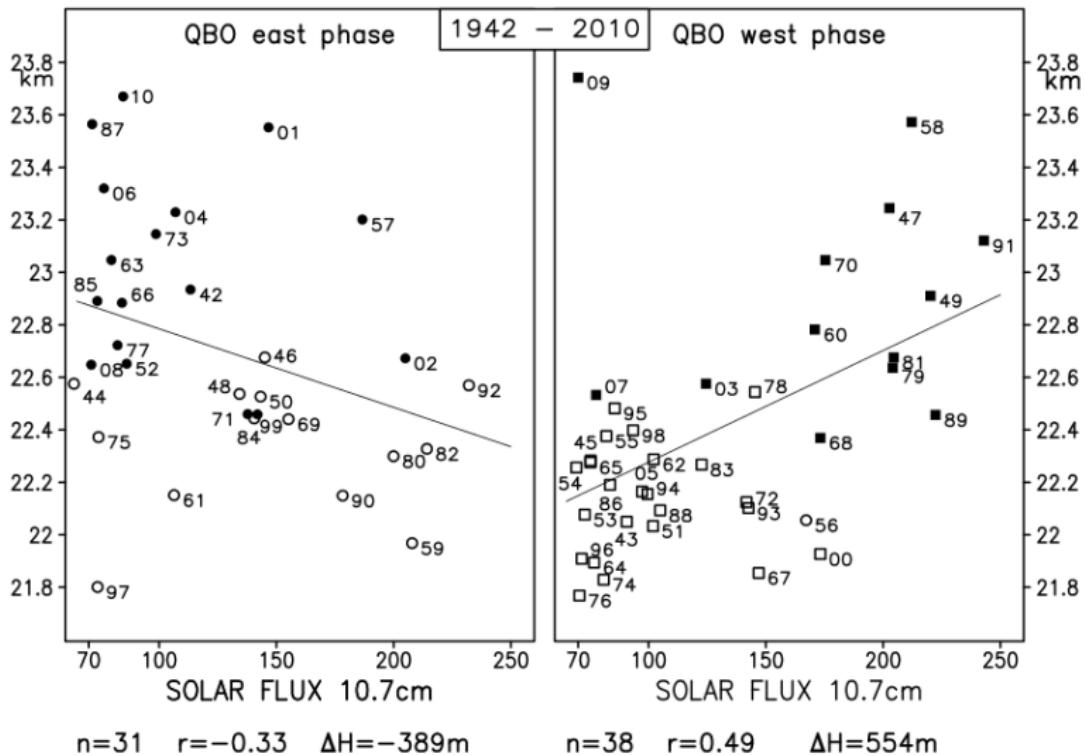
Vorhersage von polarer Variabilität

> Temperature Hindcast <



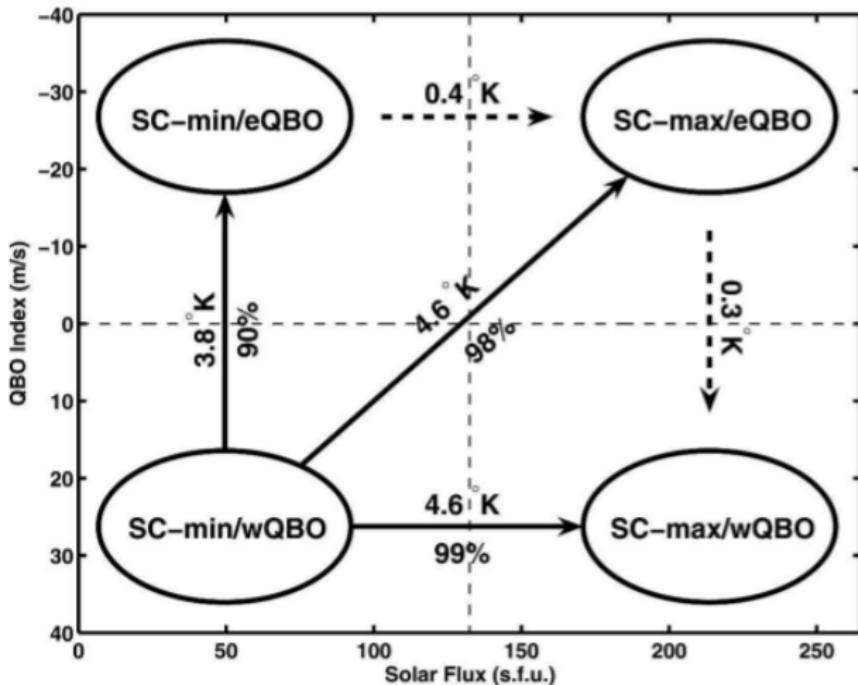
Literatur

Labitzke et al. [2006] updated



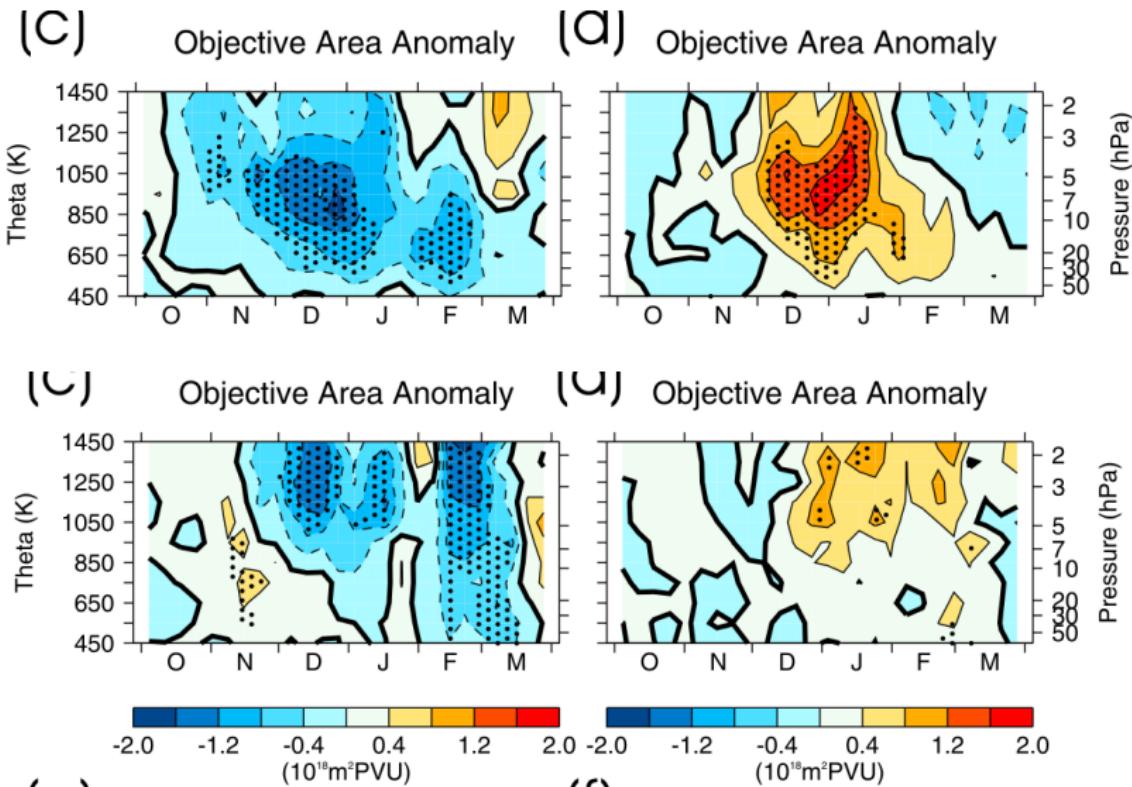
Literatur

Camp and Tung [2007]



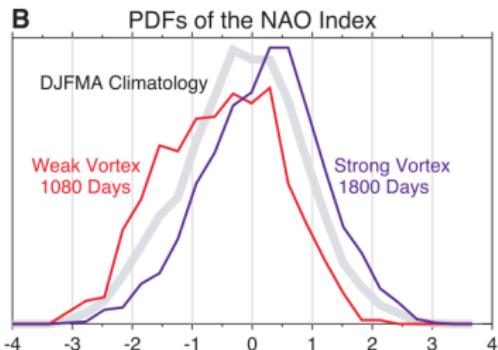
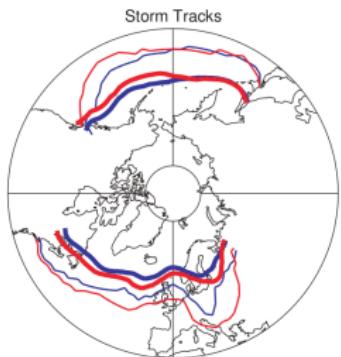
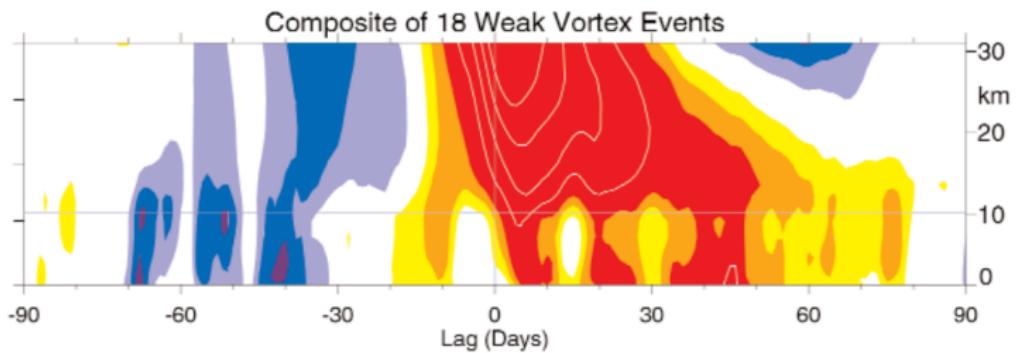
Literatur

Mitchell et al. [2011]



Literatur

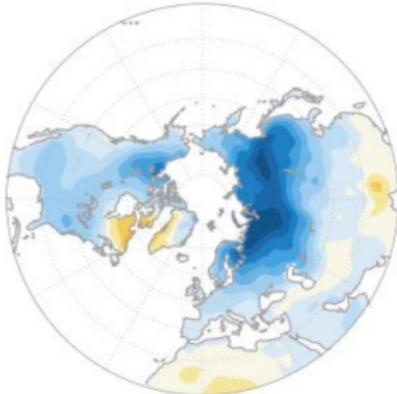
Baldwin and Dunkerton [2001]



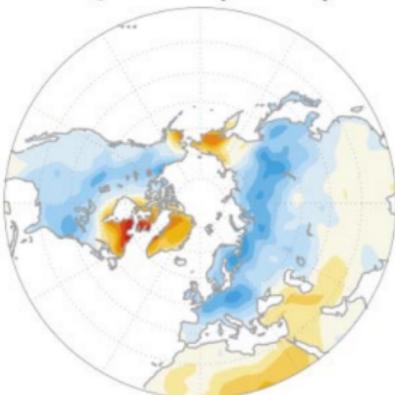
Literatur

Thompson [2003]

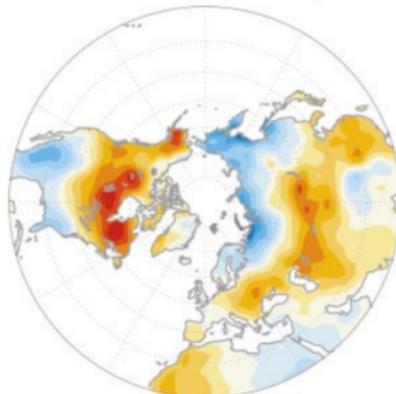
Days 1-60 following
stratospheric anomalies



QBO easterly-westerly

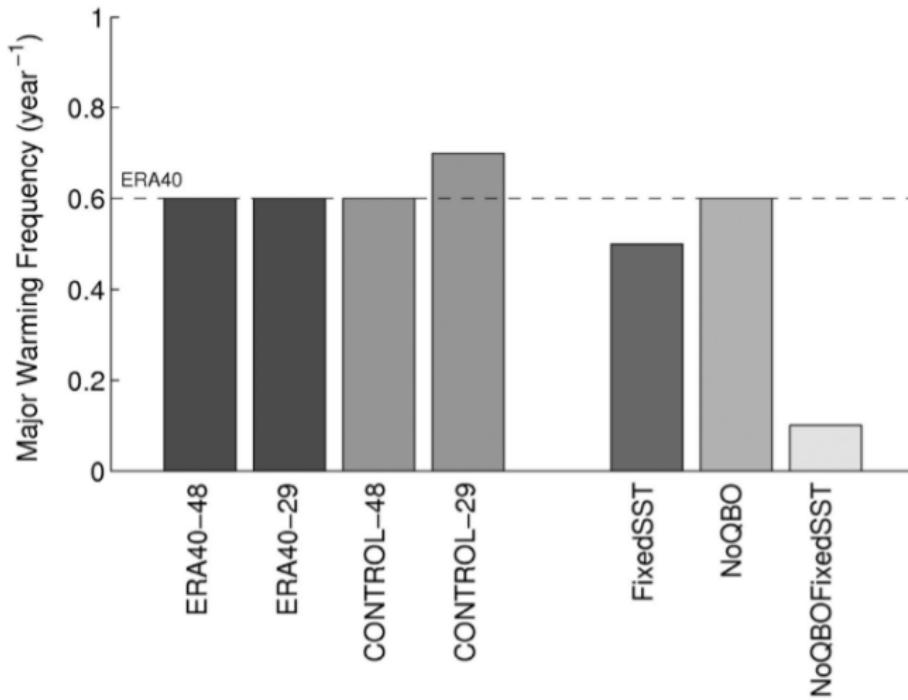


ENSO (warm-cold)



Literatur

Richter et al. [2011]



Referenzen |

- Akaike, H., 1974: A new look at the statistical model identification. *IEEE Trans. Autom. Control*, 19, 716–723.
- Ariew, R., 1976: Ockham's Razor: A Historical and Philosophical Analysis of Ockham's Principle of Parsimony. Ph.D. thesis, Champaign-Urbana, University of Illinois.
- Baldwin, M. P. and T. J. Dunkerton, 2001: Stratospheric harbingers of anomalous weather regimes. *Science*, 294, 581–584.
- Baldwin, M. P., et al., 2001: The Quasi-Biennial Oscillation. *Rev. Geophys.*, 39 (2), 179–229.
- Bishop, C., 1995: *Neural networks for pattern recognition*. Oxford: University Press, 482 pp.
- Burges, C. J. C., 1998: *A tutorial on support vector machines for pattern recognition*. 2d ed., Kluwer Academic, 121–161 pp.
- Camp, C. D. and K.-K. Tung, 2007: The influence of the solar cycle and QBO on the late-winter stratospheric polar vortex. *J. Atmos. Sci.*, 64 (4), 1267–1283.
- Charlton, A. J. and L. M. Polvani, 2007: A New Look at Stratospheric Sudden Warmings. Part I: Climatology and Modeling Benchmarks. *J. Climate*, 20, 449–469.
- Deser, C., M. A. Alexander, S.-P. Xie, and A. S. Phillips, 2010: Sea Surface Temperature Variability: Patterns and Mechanisms. *Ann. Rev. Mar. Sci.*, 2, 115–143.

Referenzen II

- Gray, L. J., et al., 2010: Solar influences on climate. *Rev. Geophys.*, 48 (4), RG4001.
- Hassler, B., G. E. Bodeker, I. Cionni, and M. Dameris, 2009: A vertically resolved, monthly mean, ozone database from 1979 to 2100 for constraining global climate model simulations. *Int. J. Remote Sens.*, 30 (15–16), 4009–4018.
- Horenko, I., 2010: On the identification of nonstationary factor models and their application to atmospheric data analysis. *J. Atmos. Sci.*, 67 (5), 1559–1574.
- Horenko, I., 2011: Nonstationarity in multifactor models of discrete jump processes, memory and application to cloud modeling. *J. Atmos. Sci.*, 68 (7), 1493–1506.
- IPCC, 2001: *Climate Change 2001: The Scientific Basis, Contribution of Working Group I to the Third Assessment Report of the IPCC*. Cambridge University Press.
- Kalnay, E., et al., 1996: The NCEP/NCAR 40-year reanalysis project. *Bull. Amer. Meteor. Soc.*, 77 (3), 437–472.
- Kohavi, R., 1995: A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proc. Int. Joint Conf. on Artificial Intelligence*, Montreal, QC, Canada, IJCAI, Vol. 2, 1137–1143.
- Labitzke, K., M. Kunze, and S. Brönnimann, 2006: Sunspots, the QBO, and the stratosphere in the north polar region - 20 years later. *Meteor. Z.*, 15 (3), 355–363.
- Liddle, A., 2008: Information criteria for astrophysical model selection. *Mon. Not. R. Astron. Soc.*, 377 (1), L47–L78.

Referenzen III

- Mitchell, D. M., A. J. Charlton-Perez, and L. J. Gray, 2011: Characterizing the Variability and Extremes of the Stratospheric Polar Vortices Using 2D Moment Analysis. *J. Atmos. Sci.*, 68, 1194–1213.
- Mitchell, D. M., L. J. Gray, and A. J. Charlton-Perez, 2011: The structure and evolution of the stratospheric vortex in response to natural forcings. *Geophys. Res. Lett.*, 116, D15110.
- Montgomery, D., E. A. Peck, and G. G. Vining, 2006: *Introduction to linear regression analysis*. 4th ed., Wiley-Interscience, 612 pp.
- North, G. R., T. L. Bell, R. F. Cahalan, and F. J. Moeng, 1982: Sampling error in the estimation of empirical orthogonal function. *Mon. Weather Rev.*, 110, 699–706.
- Randel, W. J. and A. M. Thompson, 2011: Interannual variability and trends in tropical ozone derived from SAGE II satellite data and SHADOZ ozonesondes. *J. Geophys. Res.*, 116, D07303.
- Randel, W. J. and F. Wu, 2007: A stratospheric ozone profile data set for 1979–2005: Variability, trends, and comparisons with column ozone data. *J. Geophys. Res.*, 112, D06313.
- Randel, W. J. et al., 2009: An update of observed stratospheric temperature trends. *J. Geophys. Res.*, 114, D02107.

Referenzen IV

- Richter, J. H., K. Matthes, N. Calvo, and L. J. Gray, 2011: Influence of the Quasi-Biennial Oscillation and El Niño-southern oscillation on the frequency of sudden stratospheric warmings. *J. Geophys. Res.*, 116, D20111.
- Rienecker, M. M. et al., 2011: MERRA: NASA's Modern-Era Retrospective Analysis for Research and Applications. *J. Climate*, 24 (14), 3624–3648.
- Robock, A., 2000: Volcanic eruptions and climate. *Rev. Geophys.*, 38, 191–219.
- Schwarz, G., 1978: Estimating the dimension of a model. *Ann. Stat.*, 6 (2), 461–464.
- Simmons, A., S. M. Uppala, D. Dee, and S. Kobayashi, 2006: ERA-Interim: New ECMWF reanalysis products from 1989 onwards. *ECMWF Newsletter*, 110, 26–35.
- SPARC CCMVal, 2010: SPARC Report on the Evaluation of Chemistry-Climate Models, V. Eyring, T. G. Shepherd, D. W. Waugh (Eds.). *SPARC Report No. 5, WCRP-132, WMO/TD-No. 1526*, www.atmosphysics.utoronto.ca/SPARC, C. Blume contributed to chapter 8.
- Thompson, D. W. J., 2003: Stratospheric connection to northern hemisphere wintertime weather: Implications for prediction. *J. Climate*, 15, 1421–1428.
- Turkheimer, F. E., R. Hinz, and V. J. Cunningham, 2003: On the undecidability among kinetic models: from model selection to model averaging. *J. Cereb. Blood Flow Metab.*, 23, 490–498.
- Uppala, S. M., et al., 2005: The ERA-40 re-analysis. *Q. J. Roy. Meteor. Soc.*, 131, 2961–3012.

Referenzen V

- Vapnik, V., 1995: *The Nature of Statistical Learning Theory*. Springer-Verlag, New York, 188 pp.
- Wilks, D. S., 1995: *Statistical Methods in the Atmospheric Sciences*, International Geophysics Series, Vol. 59. Academic Press, 467 pp.
- WMO, 2007: *Scientific Assessment of Ozone Depletion: 2006*. World Meteorological Organization, Geneva, 572 pp., Global Ozone Research and Monitoring Project-Report No. 50.
- Zhang, G., B. E. Patuwo, and M. Y. Hu, 1998: Forecasting with artificial neural networks: The state of the art. *Int. J. Forecasting*, 14, 35–62.